Willkommen zum Seminar





© 2024 anderScore GmbH

Apache Kafka Workshop

Vorstellung



Jan Lühr (M.Sc. Computer Science)

- Senior Software Engineer
- Schwerpunkte
 - Pragmatic Architect
 - Integration und Migration
 - Web / Mobile Engineering
 - Clean Code
 - Trainings, Artikel, Vorträge
 - Network- and Security-Techniques
 - IT-Trainer
- Java, Spring, JEE, Kafka, Android, Microservices,...



Vorstellung anderScore GmbH



Individuelle Anwendungsentwicklung - Java Enterprise, Web, Mobile

- seit 2005 ♦ in Köln ♦ für alle Branchen ♦
- nach Aufwand & zum Festpreis
- Digitalisierung / Prozesse / Integration
- ✓ Migration
- Neuentwicklung
- ✓ Notfall / kritische Situation
- pragmatisch, zielgerichtet, zuverlässig

Kompletter SW Life Cycle

- Projektmanagement / agile Methodik
- Anforderungsanalyse
- Architektur & SW-Design
- Implementierung & Testautomation
- Studien & Seminare





Apache Kafka Workshop

07.03. - 08.03.24

Jan Lühr



Agenda



Begrüßung

- 1. Einführung
- 2. Paradigmen und Funktionsweise
- 3. Komponenten
- 4. Implementierung von Clients
- 5. Analyse und Transformation
- 6. Broker Operations
- 7. Best Practices
- 8. Ausblick



Lektion 1 - Einführung

Inhalt und Ziel



- Workshop
 - Einführung in grundlegende Kafka-Konzepte
 - Überwindung von Einstiegshürden
 - Funktionen und Features mit Aufgaben erarbeiten

- Zielgruppe
 - Softwareentwickler:innen, Architekt:innen und DevOps mit guten Java-Kenntnissen

- Voraussetzungen
 - Gute Java Kenntnisse
 - Sicherheit im Umgang mit einer IDE (z.B. IntelliJ)

Zeitplan



Beginn	09:00 Uhr
Kaffeepause	ca. 10:30 Uhr
Mittagspause	12:00 bis 13:00 Uhr
Ende	16:00 Uhr

Remote Training



- Video-Konferenz über Zoom
 - Bildschirmfreigabe für Folien
 - Lautsprecher + Mikrofon benötigt, Kamera empfehlenswert
 - Zugangsdaten, um Rechner per Web-Browser zu erreichen:

https://connect.gfu.cloud/

Username / Password folgt im Problemfall

- Entwicklung: Remote Desktop Protocol (RDP) zur GFU
 - Praktische Übungen
 - Ubuntu VM
 - Aufschaltung über Zoom möglich
- Material auf GitHub

https://github.com/anderscore-gmbh/kafka-24.03.1

Hybrid Training



Vereinbarungen

- Pausen
 - Gemeinsam zu vorgegebenen Zeiten
 - Individuell während der Übungen
- Erreichbarkeit Dozent
 - Zoom (Chat, Mikrofon)
 - E-Mail
- Regeln
 - Mikrofon möglichst aus (Hintergrundgeräusche)
 - Bei Fragen: "Hand heben" oder Chat
 - Wenn Übung fertig, selbst in Hauptsession zurückkehren

Material



- Kafka Quickstart
 - https://kafka.apache.org/quickstart
- Kafka Cheat Sheet
 - https://github.com/lensesio/kafka-cheat-sheet
- Kafka E-Book
 - https://www.confluent.io/resources/kafka-the-definitive-guide

Vorstellung



Jetzt sind Sie dran!

- Name
- Vorwissen
- Erwartungen
- Themenwünsche



Ihre Umgebung



- Kafkacat
- JDK 17
- Maven
- Entwicklungsumgebung (z.B. IntelliJ)
- Docker Desktop oder Docker Engine

Aufgabe 0 – Hello World mit kafkacat/kcat



Aufgabenstellung:

- Installieren Sie kafkacat bzw. kcat auf Ihrem System
- Senden Sie eine Nachricht an broker-1.k.anderscore.com:9092 Topic: HelloWorld
- Konsumieren Sie alle Nachrichten des Topics und geben Sie diese aus

Hinweise:

- Ubuntu / Debian (ggf. vorinstalliert): apt-get install kafkacat
- Nachricht senden:

```
echo "Hallo Welt" | kafkacat -b broker-1.k.anderscore.com -t HelloWorld
```

Nachricht konsumieren:

kafkacat -b broker-1.k.anderscore.com -t HelloWorld

Aufgabe 0 – Hello World mit kafka-console-producer/consumer



Kafka Archiv herunterladen und entpacken:

https://dlcdn.apache.org/kafka/3.7.0/kafka 2.13-3.7.0.tgz

Nachricht in das Topic schreiben:

```
$ bin/kafka-console-producer.sh --topic HelloWorld --bootstrap-server broker-
1.k.anderscore.com:9092
This is my first event
This is my second event
```

Nachricht aus Topic auslesen:

```
$ bin/kafka-console-consumer.sh --topic HelloWorld --from-beginning --bootstrap-server broker-1.k.anderscore.com:9092
```

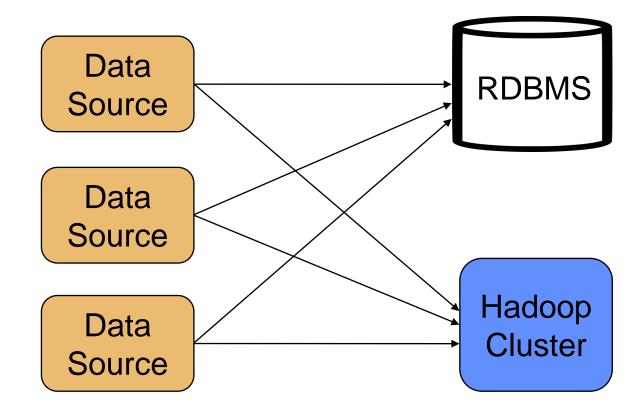


Lektion 2 - Paradigmen und Funktionsweise von Kafka

Was ist Kafka?



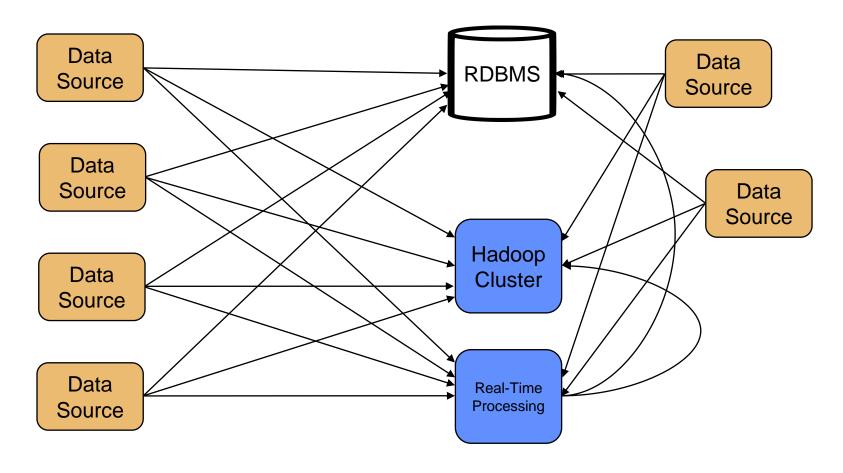
Einfache Datenverteilung:



Was ist Kafka?



Komplexe Datenverteilung:



Motivation für Kafka



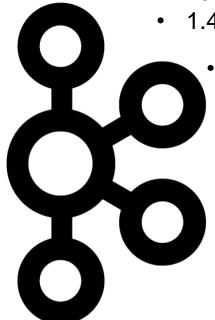
Motivation

- Komplexe Datenverteilung bewältigen
- Batch-Verarbeitungsprozess verbessern
- Zeitnahe Verarbeitung ermöglichen
- Ziele von Kafka
 - Pipelines vereinfachen
 - Data Stream Handling
- Ansatz
 - Stream Data Platform: Stream Processing statt Batch Processing
 - Middleware f
 ür persistente Logs / Streams
 - Ähnlich zu MQTT und Message Queuing

Apache Kafka



- Enstanden auf LinkedIn (2010)
 - Teil der Core-Architektur
 - 1.4 Milliarden Nachrichten pro Tag



Genutzt von:

- IBM, zalando, airbnb, Cisco, Netflix, Paypal, Twitter...
- Use Cases:
 - Event Verarbeitung (quasi realtime)
 - Log Aggregation
 - Metriken & Analyse
 - Messaging / µService Kommunikation
- Keine Realtime- bzw. Echtzeitverarbeitung (Werbeversprechen; im Sinne von Reordering Queues)

Kafka-Versionen



- Aktuell: Version 3.7.0
- Release Notes der Versionen unter

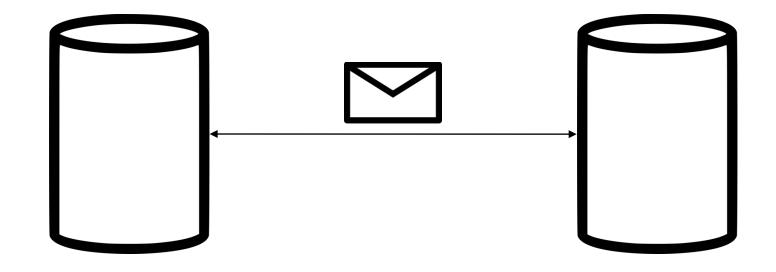
https://downloads.apache.org/kafka/3.7.0/RELEASE_NOTES.html

Upgrade auf neue Version und Changelog unter

https://kafka.apache.org/blog#apache_kafka_370_release_announcement

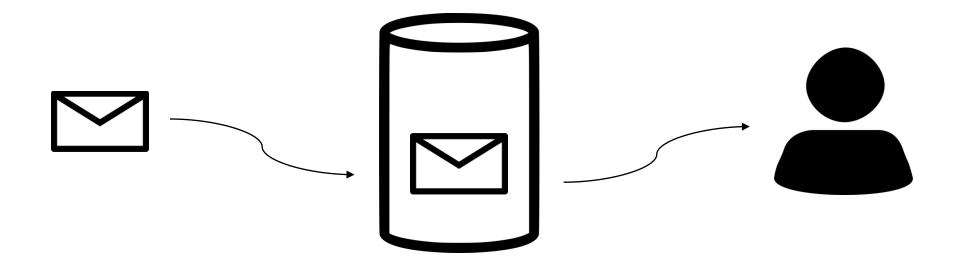
Synchrone Kommunikation



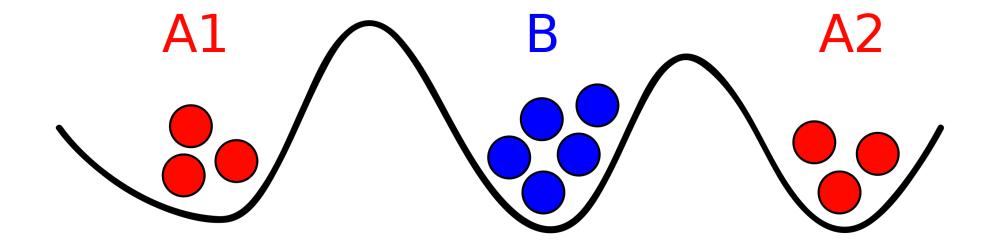


Asynchrone Kommunikation

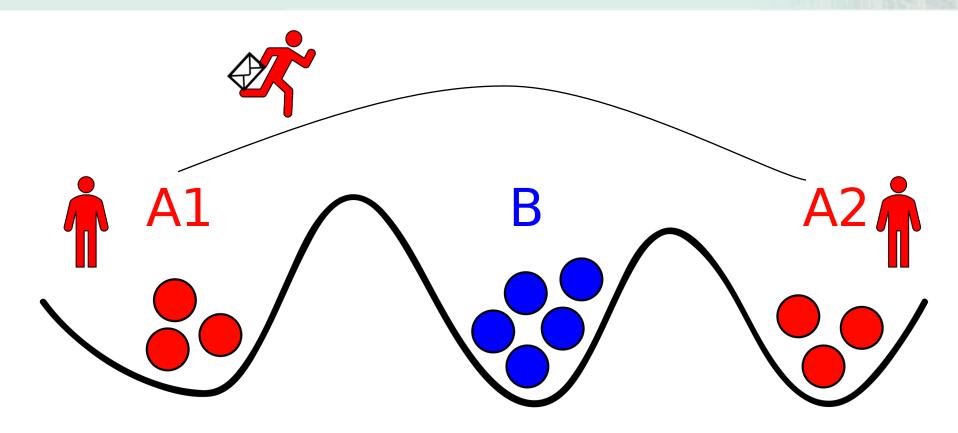




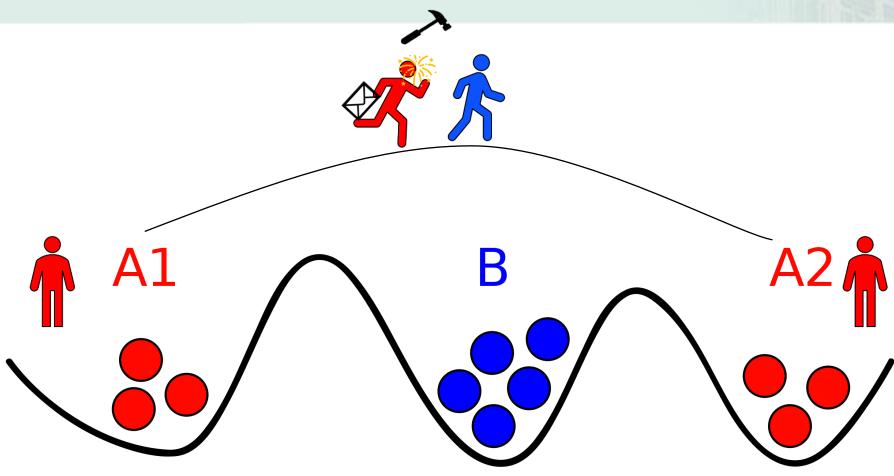




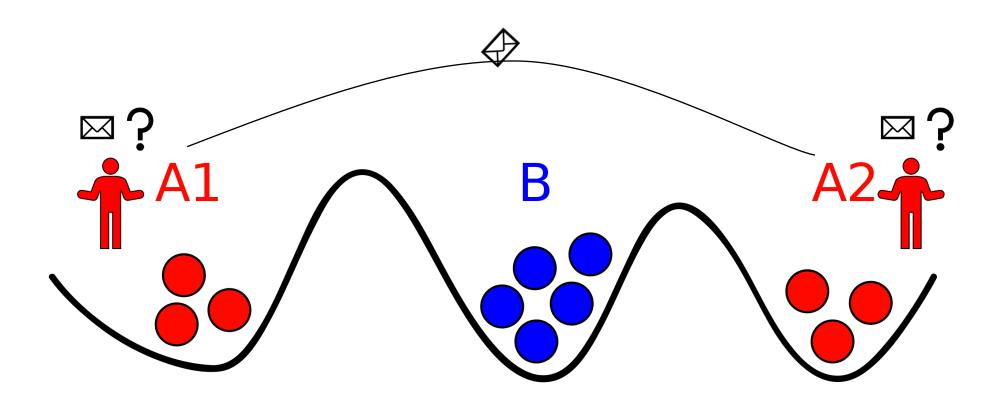












Idempotenz



Definition:

Eine Operation, welche mehrfach hintereinander ausgeführt das gleiche Ergebnis wie bei einer einzigen Ausführung liefert.

https://de.wikipedia.org/wiki/Idempotenz

Semantik beim Aufruf



Was passiert bei einem Fehler?

- At least once
 - Mindestens ein Mal: Risiko von Duplikaten
- At most once
 - Maximal ein Mal: Kein Neuversuch beim Fehlschlag
- Exactly once
 - Genau ein Mal: In Praxis schwer zu erreichen

At Least Once Beispiel: Print Server



At Least Once



Situation: Druckfehler / Toner leer: Ausdruck zu hell!

- 1. Fehler wird behoben
- 2. Alle Seiten in der Warteschlange werden gedruckt
- 3. ... sehr viel Papier

At Most Once Beispiel: Print Server



At Most Once



Situation: Druckfehler / Toner leer: Ausdruck zu hell!

- 1. Fehler wird behoben
- 2. Keine Seite in der Warteschlage wird gedruckt
- 3. ... hin und her laufen.

Exactly Once Beispiel: Print Server



Exactly Once



Situation: Druckfehler / Toner leer: Ausdruck zu hell

- 1. Fehler wird behoben
- 2. Genau die zu hellen Seiten werden gedruckt
- 3. ... Perfekt ©

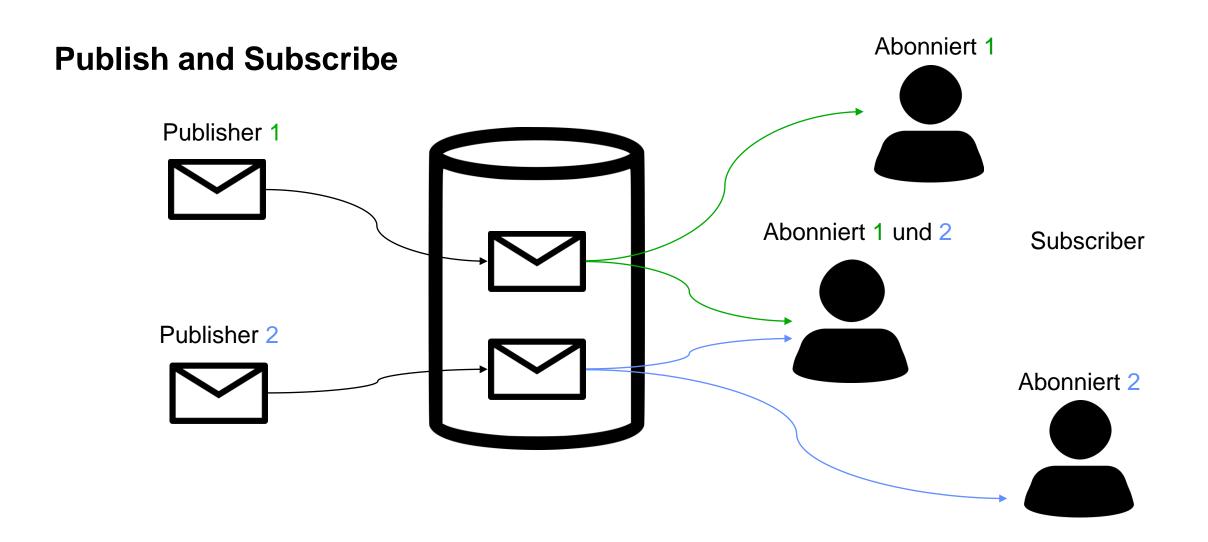
Woher weiß der Drucker, welche Seiten zu hell sind?

- Idee: Seitennummer am Bedienfeld eingeben
- Im Allgemeinen: schwer umsetzbar
- Idee auch bei Kafka: Stand der Verarbeitung im Ergebnis speichern

https://www.confluent.io/de-de/blog/exactly-oncesemantics-are-possible-heres-how-apache-kafka-does-it/

Paradigmen in Kafka





Paradigmen in Kafka



Active Polling

Konzept:

- Es wird nicht automatisch an alle Subscriber gesendet (vgl. Observer Pattern)
- Subscriber senden zyklisch Anfragen
- Existiert neuer Inhalt, wird er als Antwort zurückgeliefert

Paradigmen in Kafka



Event Sourcing

Konzept:

- Veränderung eines Zustandes = Event
- Nach Empfang neuer Daten werden alte nicht gelöscht
- Neue Events werden kontinuierlich im Event Store an alte angehängt
- Kafka: Retention Policy

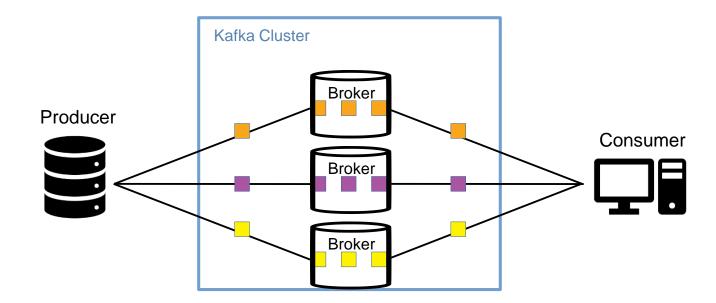
Zweck:

- Kein Informationsverlust
- Analysemuster
- Macht Kafka zu einem Hybrid aus Datenbank und Messaging System

High-Level-View of Kafka



- Producer senden Nachrichten an den Kafka-Cluster
- Consumer lesen Nachrichten vom Kafka-Cluster
- Broker sind die Speicher- und Nachrichtenkomponenten des Kafka-Clusters
- Die kleinste Einheit an Daten in Kafka sind Messages, sie werden gruppiert in sogenannten Topics



Aufgabe 1 – Hello Kafka World



Aufgabenstellung Kafka Quickstart

- Laden Sie das aktuelle Kafka Release herunter http://kafka.apache.org/quickstart
- Starten Sie das Kafka Environment in der Linux Shell
- Legen Sie ein Topic an
- Schreiben Sie einige Nachrichten in das Topic
- Lesen Sie die Nachrichten aus dem Topic aus

Aufgabe 1.1 - Hinweise Quickstart



Kafka Quickstart

- 1. Download Kafka https://dlcdn.apache.org/kafka/3.7.0/kafka_2.13-3.7.0.tgz
- 2. Kafka entpacken

```
$ tar -xzf kafka_2.13-3.7.0.tgz
$ cd kafka_2.13-3.7.0
```

- 3. Zookeeper starten
 - \$ bin/zookeeper-server-start.sh config/zookeeper.properties
- 4. In einem neuen Terminal Kafka Broker starten
 - \$ bin/kafka-server-start.sh config/server.properties

Aufgabe 1.1 - Hinweise Quickstart



Topic erzeugen

\$ bin/kafka-topics.sh --create --topic HelloWorld --bootstrap-server localhost:9092

Topic prüfen

```
$ bin/kafka-topics.sh --describe --topic HelloWorld --bootstrap-server localhost:9092
Topic: quickstart-events TopicId: NPmZHyhbR9y00wMglMH2sg PartitionCount: 1
ReplicationFactor: 1 Configs:
Topic: quickstart-events Partition: 0 Leader: 0 Replicas: 0 Isr: 0
```

Aufgabe 1.1 - Hinweise Quickstart



Nachricht in das Topic schreiben

```
$ bin/kafka-console-producer.sh --topic HelloWorld --bootstrap-server localhost:9092
This is my first event
This is my second event
```

Nachricht aus Topic auslesen

\$ bin/kafka-console-consumer.sh --topic HelloWorld --from-beginning --bootstrap-server localhost:9092

Aufgabe 1.2 - Confluent



Was ist Confluent?

- Confluent ist ein Unternehmen, das sich auf Event-Streaming-Lösungen spezialisiert hat.
- Die Hauptplattform, die Confluent Platform, basiert auf Apache Kafka.
- Confluent bietet Dienste und Tools für die Echtzeitverarbeitung, Verwaltung und Analyse großer Datenmengen.
- Ihre Lösungen helfen Unternehmen, Datenströme zu verwalten, Ereignisdaten in Echtzeit zu verarbeiten,
 Anwendungen zu integrieren und skalierbare Echtzeit-Analytik durchzuführen.

Materialien

https://docs.confluent.io/platform/current/platform.html

Aufgabe 1.2 - Confluent



Voraussetzungen

- Docker Desktop oder Docker Engine ist installiert
- Docker läuft, prüfen mit docker info

Aufgabenstellung

- Starten Sie den kafka broker mit Confluent
- Legen Sie ein Topic an
- Initialisieren Sie einen Producer, der eine "Hello World" Nachricht in das Topic schreibt
- Initialisieren Sie einen Consumer von einem anderen Kafka Terminal, welcher Nachrichten aus dem Topic liest

Materialien

Confluent Quickstart https://developer.confluent.io/quickstart/kafka-local/

Aufgabe 1.2 - Confluent



Kafka broker mit Confluent starten

\$ sudo confluent local kafka start --kafka-rest-port 9092

Topic anlegen

\$ sudo confluent local kafka topic create HelloWorld

Producer initialisieren

\$ sudo confluent local kafka topic produce HelloWorld

Consumer initialisieren

\$ sudo confluent local kafka topic consume HelloWorld --from-beginning

Kafka broker stoppen

\$ sudo confluent local kafka stop

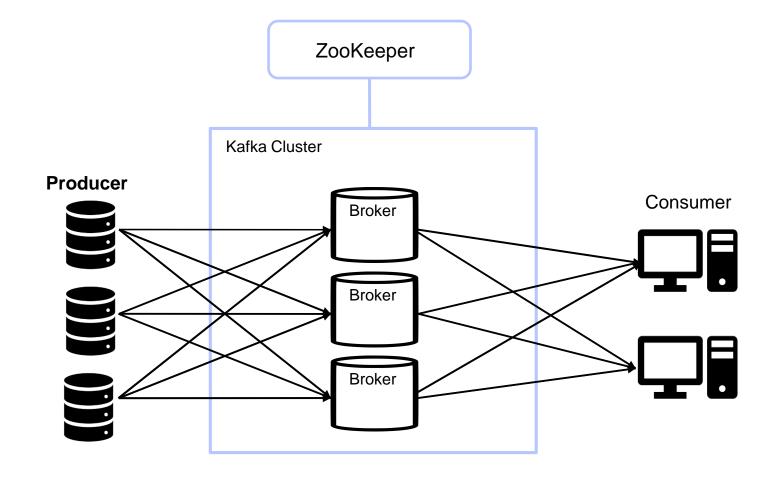


Lektion 3 – Komponenten

Kafka Komponenten



- Producer
- Broker
- Consumer
- Zookeeper



Kafka Komponenten: Producer



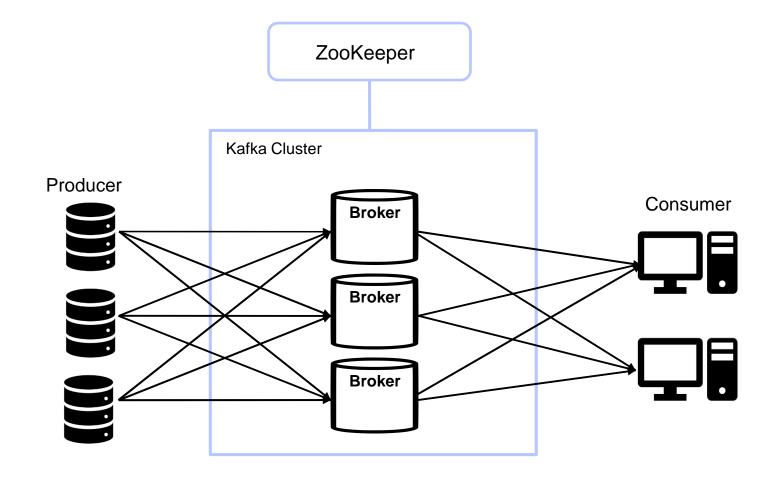


- Teil einer Anwendung
- Senden Daten an den Kafka Cluster
- Sharding der Messages (Partitionierung)
 - Über Hash Key oder Round Robin
 - Alternativ auch über eigene Strategie
 - Load Balancing: Verteilung der Last über Broker
 - Semantic Partitioning: User spezifischer Key
- Anbindung über:
 - Nativ: Java, C/C++, Python, Go, .Net, JMS
 - REST (Confluent)
- Zusätzlich existieren Implementierungen für viele andere Sprachen

Kafka Komponenten

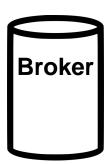


- Producer
- Broker
- Consumer
- Zookeeper



Kafka Komponenten: Broker

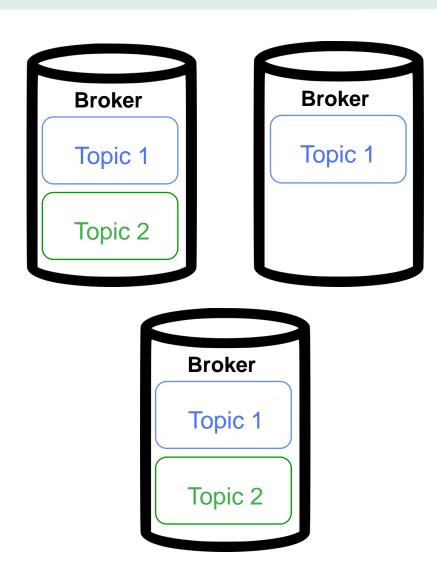




- Server Prozess (aktiv)
- Storage und Messaging Komponente
- Empfängt und speichert Nachrichten
- Message-Speicher: Direkt auf Hard Disk (Zero Copy)
- Existiert mehrfach pro Cluster
- Bedient Client Prozesse
- Weist Clients individuelle Offsets zu
- Verwaltet mehrere Topics und Partitionen

Kafka Komponenten: Topic



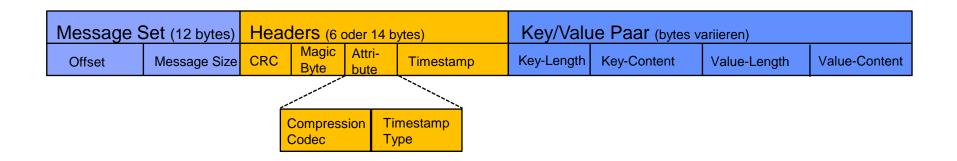


- Logischer Name eines Streams
- Gruppiert Messages
- "Beliebig" viele pro Cluster
- Von Kafka verwaltet
- Von Entwickler(in) administriert
- Cleanup-policy: compact vs. delete
- Segment Size: head vs. tail
- Besteht aus mehreren Partitions

Kafka Komponenten: Message

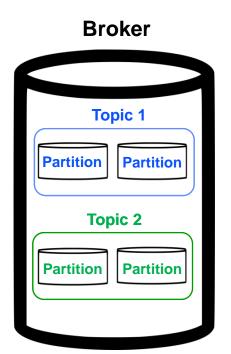


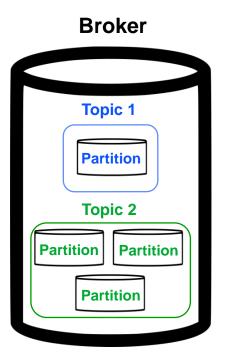
- Eine Message ist ein Key-Value Paar; Key und Value k\u00f6nnen von beliebigem Datentyp sein
- Messages enthalten Daten und Metadaten:
 - Key/Value Paar
 - Offset
 - Timestamp
 - Compression type



Kafka Komponenten: Partition



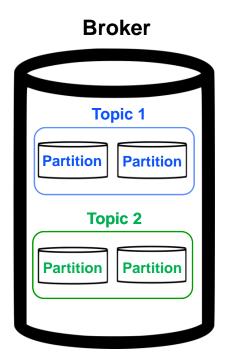


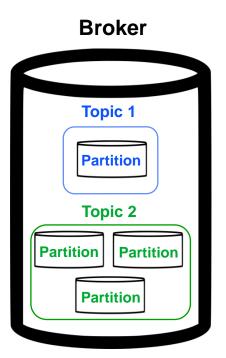


- Jede Partition enthält eine Teilmenge der Nachrichten einer Topic; üblich: Message Key zur Zuordnung einer Partition
- Lokale Ordnung innerhalb einer Partition, append-only
- Identifier innerhalb einer Partition: Offset einer Message, wachsend
- Replication zwischen Brokern möglich → Fault Tolerance

Kafka Komponenten: Partition

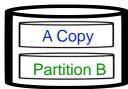


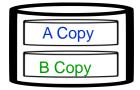


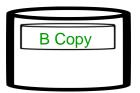


- Jede Partition enthält eine Teilmenge der Nachrichten einer Topic; üblich: Message Key zur Zuordnung einer Partition
- Lokale Ordnung innerhalb einer Partition, append-only
- Identifier innerhalb einer Partition: Offset einer Message, wachsend
- Replication zwischen Brokern möglich → Fault Tolerance



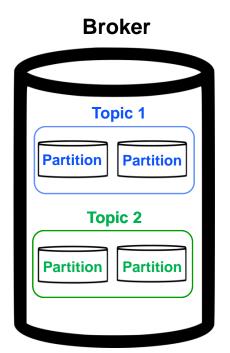


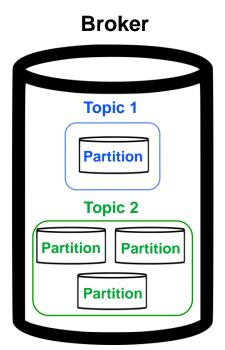




Kafka Komponenten: Partition







- Jede Partition enthält eine Teilmenge der Nachrichten einer Topic; üblich: Message Key zur Zuordnung einer Partition
- Lokale Ordnung innerhalb einer Partition, append-only
- Identifier innerhalb einer Partition: Offset einer Message, wachsend
- Replication zwischen Brokern möglich → Fault Tolerance
- Clients lesen nur vom Leader
- Head: in-memory
- Tail: persistent (Deletion & Compaction)
- Drift konfigurierbar

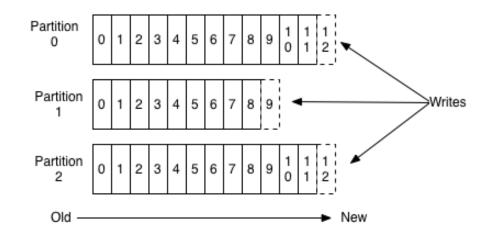
Anatomie eines Topics



Aufbau:

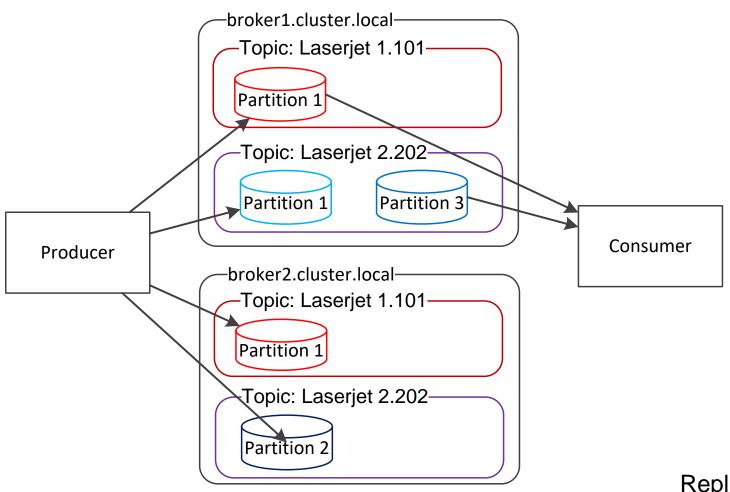
- Cluster besteht aus 1...n Brokern
- Ein oder mehrere Producer können in eine oder mehrere Topics schreiben
- Messages einer Topic sind in über 1...m
 Partitions in verschiedenen Brokern verteilt

Anatomy of a Topic



Partitionen: Printer Beispiel





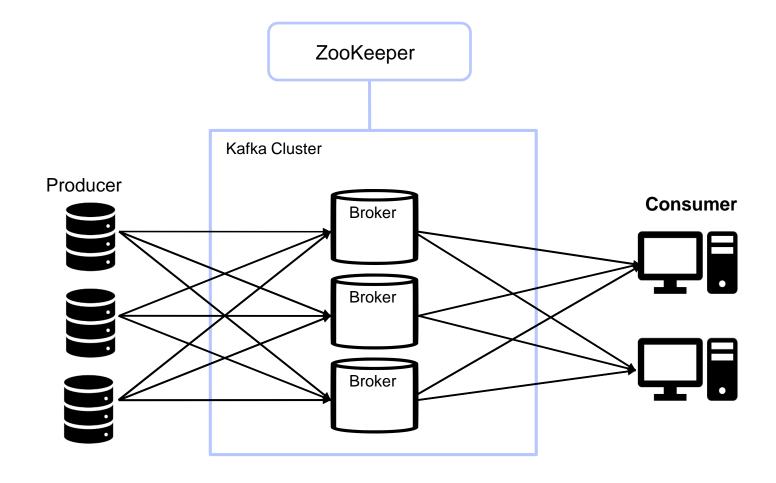
Repliziert: Laserjet 1.101

Sharding: Laserjet 2.202

Kafka Komponenten



- Producer
- Broker
- Consumer
- Zookeeper



Kafka Komponenten: Consumer



Abruf von Messages via pull, single-threaded

Consumer Offset

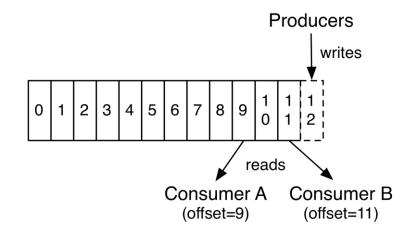
- Nächste zu lesende Nachricht
- Pro Consumer und Partition
- Speicher: spezielles internes Topic (oder extern)
- Commit: automatisch (default: 5 sec Obacht!) oder manuell

Semantik:

- At least once: Nachricht bearbeiten danach Commit
- At most once: Commit, danach Nachricht bearbeiten
- Exactly once: Offset im Zielsystem speichern (lokale Transaktion)

Verschiedene Consumer

- Gleichzeitiges Lesen möglich
- Default: Alle Nachrichten im Topic an alle Consumer
- Spezialfall: Consumer Group

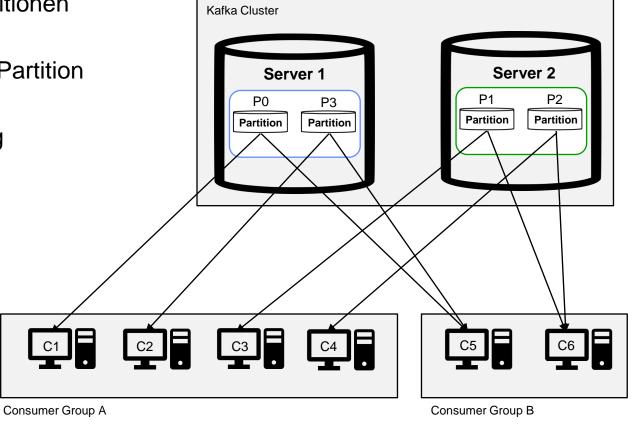


https://docs.confluent.io/platform/current/clients/consumer.html

Kafka Komponenten: Consumer Groups



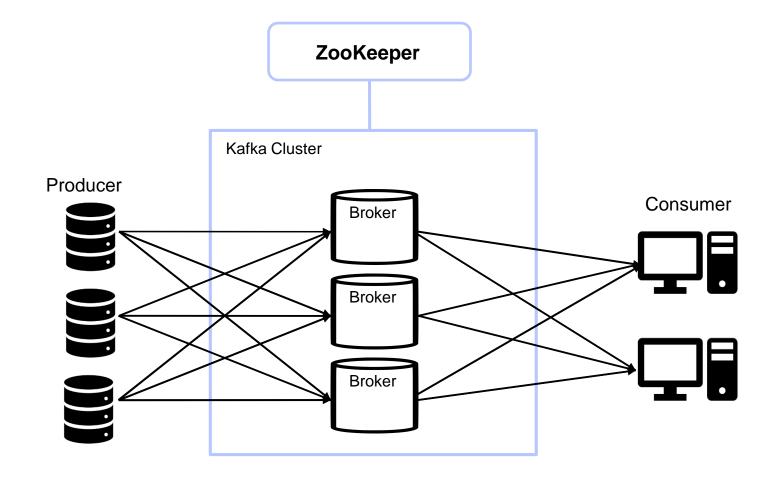
- Gruppierung: Consumer Group
 - Mehrere Consumer zusammenfassen → Consumer Group
 - Jeder Consumer bearbeitet nur Subset der Partitionen
 - Eindeutige Group ID
 - Jeder Consumer in einer Group braucht eigene Partition
 - Ein Subset von Partitionen
 - Automatisches Error-Handling & Load-Balancing
- Scaling
 - Maximal ein Consumer pro Partition pro Gruppe
 - #Consumer ≤ #Partitions
 - #Partition ändern: Schwer möglich
 - Besser: Neues Topic bei Release-Wechsel (API-Versionierung)



Kafka Komponenten



- Producer
- Broker
- Consumer
- Zookeeper



Zookeeper



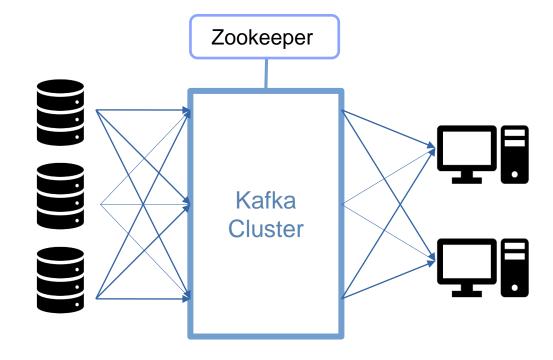
- Was ist Zookeeper?
 - Open Source von Apache
 - Ermöglicht verteilte Koordination
 - Kümmert sich um Konfigurationsinformationen
 - Bietet verteilte Synchronisation
- Besteht aus drei oder fünf Servern im Quorum.
 - Quorum:
 - Eine replizierte Gruppe von Servern in der gleichen Applikation nennt man Quorum
 - Im replicated mode haben alle Server im Quorum eine Kopie der gleichen Config Datei

Zookeeper in Kafka



Kafka Broker nutzen **Zookeeper** für:

- Cluster Management
- Fehlerfindung und Wiederherstellung
- Speicherung von Access Control Lists (ACL)



Aufgabe 2 – Topics und Partitionen



Aufgabenstellung:

- Erstellen Sie ein Topic mit 2 Partitionen auf dem Broker, welchen Sie in Aufgabe 1 eingerichtet haben
 - Alternativer Broker: broker-1.k.anderscore.com
- Welche Funktion und Auswirkung haben die Parameter:
 - segment.ms und segment.bytes
 - cleanup.policy = delete (oder compact)
 - retention.ms oder retention.bytes
 - min.cleanable.dirty.ratio
- Schreiben Sie die Zahlen 0...42 in das Topic und lesen Sie sie daraus. Wie sind die Zahlen geordnet?

Aufgabe 2 - Hinweise



Hinweise:

- Verwenden Sie die Kafka Command Line Tools um das Topic anzulegen
- Topic erzeugen:

bin/kafka-topics.sh --bootstrap-server localhost:9092 --create --topic myTopic -partitions 2 --replication-factor 1

Aufgabe 2 - Hinweise



Nachricht senden:

```
for zahl in `seq 0 42`; do echo $zahl | bin/kafka-console-producer.sh --broker-list localhost:9092 --topic myTopic; done.
```

Hinweis: Schneller geht's auch mit kafkacat statt kafka-console-producer.sh, da kein JVM-Process pro Iteration erzeugt wird – kafka-console-producer.sh bringt jedoch mehr Optionen

Nachricht Lesen:

```
bin/kafka-console-consumer.sh --bootstrap-server localhost:9092 --from-beginning --topic myTopic
```



Lektion 4 – Implementierung von Clients

Java APIs für Kafka



Java Producer API

- Kafka Client, welcher Datensätze zum Kafka Cluster published
 - Thread Safe
 - Dependency Injection Scope: Singleton
 - Pufferung bei Verbindungsverlust

Java Consumer API

- Kafka Client, welcher Datensätze aus einem Kafka Cluster konsumiert
 - Transparenz bei Fehlern von Brokern
 - Passt sich an Migrationen von Partitionen im Cluster an
 - Interagiert mit Broker und erlaubt Zugriff auf dessen Consumer Groups

Producer Eigenschaften



Name	Beschreibung
bootstrap.servers	Liste der Broker host/port Paare für initiale Verbindung zum Cluster
key.serializer/ value.serializer	Klasse zur Serialisierung von Keys/ Values. Muss das Serializer Interface implementieren
acks	Anzahl an Bestätigungen (Acknowledgements), die der Producer benötigt, bevor der Request fertig ist. acks=0: Producer wartet nicht auf Bestätigungen vom Server acks=1: Producer wartet, bis der Datensatz auf den Leader geschrieben wurde acks=all: Producer wartet, bis alle in-sync Replikate das Erhalten der Datensätze bestätigt haben

Properties props = new Properties();
props.puts(setting, value);

Java Producer API



Erstellung eines Producers:

Klasse

```
public class KafkaProducer<K,V>
```

Wichtige Eigenschaften und Senden

Nachricht an Kafka senden



- Die send () Methode ist non-blocking
 - Gibt Datensatz in einen Buffer von wartenden Datensätzen über und gibt sofort ein Return zurück
 - Effizienz: Batched einzelne Datensätze zusammen
 - Falls nötig kann mit .send(record).get() ein block geforced werden

```
ProducerRecord<String, String> record = new ProducerRecord<String, String>("my-topic", "myKey", "myValue");
Future<RecordMetadata> metadata = producer.send(record);
producer.close();
```

Retries:

- Wie oft versucht der Producer bei einem Fehler Records erneut zu senden
- Kann zu Änderung in der Reihenfolge der Nachrichten führen!
- Anzahl der Connections kann angepasst werden

```
retry.backoff.ms=100 (Pause zwischen retries)
retries=600 (Anzahl retries)

# default ist 5
set max.in.flight.requests.per.connection=1
```

Buffer beim Versenden



Default Linger:

- Buffer sendet sofort, auch bei ungenutztem Space
- Um die Anzahl an Requests zu verringern, kann Wartezeit konfiguriert werden
- Erhöht Effizienz bei minimaler Latenz

```
# größer als 0
linger.ms = 1
```

Buffer Größe:

- Gesamtmenge an Speicher, welcher dem Producer für den Buffer zu Verfügung gestellt wird
- Wenn der Buffer voll ist, werden Send Requests geblockt (TimeoutException)

```
buffer.memory max.block.ms
```

Callbacks



- send(record) äquivalent zu send(record, null)
- → Callback in zweitem Parameter überliefern

Reaktion auf Fehler:

Fehler: Metadata ist null

Kein Fehler: Exception ist null

Consumer Eigenschaften



Name	Beschreibung
bootstrap.servers	Liste der Broker host/port Paare für initiale Verbindung zum Cluster
key.deserializer/ value.deserializer	Klasse zur Deserialisierung von Keys/ Values. Muss das Deserializer Interface implementieren
group.id	Zeigt an, zu welcher Consumer Group der Consumer gehört
enable.auto.commit	Bei true triggered der Consumer offset commits

Properties props = new Properties();
props.setProperty(setting, value);

Java Consumer API



Erstellung eines Consumers:

Klasse

```
public class KafkaConsumer<K,V>
```

Wichtige Eigenschaften und Polling

Nachricht aus Kafka lesen



- Die poll () Methode gibt alle verfügbaren Nachrichten zurück
 - Bis zu der maximalen Größe per Partition

default 1048576 bytes
max.partition.fetch.bytes

- Eine zu hohe Anzahl an Partitionen kann extreme Mengen an Daten zurückgeben
 - Gesamtmenge von Datensätzen in einem einzelnen Poll kann reduziert werden (Chunking)

max.poll.records

Aufgabe 3 – Producer und Consumer



Aufgabenstellung:

- Erzeugen Sie ein neues Java Projekt und binden Sie den Kafka Client ein
- Verbinden Sie sich mit Ihrem Kafka Broker
- Implementieren Sie einen Consumer: Lesen Sie alle Nachrichten aus dem Topic "HelloWorld" aus
- Geben Sie die Nachrichten auf der Konsole aus
- Implementieren Sie einen Producer

Aufgabe 3 - Hinweise



- Im einfachsten Fall können Sie Kafka-Events ohne weitere Frameworks konsumieren.
- Hierzu müssen die entsprechenden Bibliotheken in das Projekt angebunden werden.

Erstellen Sie ein neues Maven Projekt z.B. mit:

```
mvn archetype:generate -DgroupId=gs -DartifactId=kafka \
-DarchetypeArtifactId=maven-archetype-quickstart \
-DinteractiveMode=false
```

- Fügen Sie dann die Maven Dependency der Datei pom.xml hinzu
- Nutzen Sie die folgenden Klassen:

```
org.apache.kafka.clients.consumer.KafkaConsumer
org.apache.kafka.clients.producer.KafkaProducer
```

Offsets spezifizieren



- Consumer property auto.offset.reset legt fest, was bei bei einem ungültigem Offset in Kafka für die
 Consumer Group des Consumers passiert
 - Wenn eine Consumer Group das erste mal startet
 - Wenn das Consumer Offset kleiner als das kleinste Offset ist
 - Wenn das Consumer Offset größer als das letzte Offset ist

Kann gesetzt werden auf:

- earliest: Automatischer Reset des Offsets zu kleinstem verfügbarem Wert
- latest (default): Automatischer Reset des Offsets zu letztem verfügbarem Wert
- none: Excepton, wenn kein früheres Offset für die Consumer Group gefunden werden kann

Offsets ändern - Consumer



 KafkaConsumer API unterstützt Ansehen der Offsets und dynamisches Ändern des Nächsten zu Lesenden Offsets

View Offsets:

- position (TopicPartition): Offset der nächsten Nachricht
- offsetsForTimes (Map<TopicPartition, Long> timestampsToSearch): sucht die Offsets für die angegebenen Partitionen nach Zeitstempel

Change Offsets:

- seekToBeginning(Collection<TopicPartition>): Sucht erstes Offset von jeder der angegebenen Partitionen
- seekToBeginning(Collection<TopicPartition>): Sucht letztes Offset von jeder der angegebenen Partitionen
- seek (TopicPartition, offset): Sucht angegebenes Offset in angegebener Partition

Offsets ändern - Consumer



 Beispiel: Suchen bis zum Anfang aller Partitions, die von einem Consumer zu einer bestimmten Topic gelesen werden

```
consumer.subscribe(Arrays.asList("MyTopic"));
consumer.poll(0);
consumer.seekToBeginning(consumer.assignment());
```

Offsets manuell comitten



Default: enable.auto.commit ist auf true, alle 5 Sekunden, während des poll() Aufrufes

Problem:

- Szenario: Zwei Sekunden nach dem letzten Commit wird ein Rebalance ausgelöst, nach Rabalance starten Consumer bei der letzten Offset Position, die comitted wurde
- → In diesem Fall: Offset ist zwei Sekunden und alle Nachrichten aus diesen zwei Sekunden werden zweimal verarbeitet! (At least once)

Offsets manuell comitten



- enable.auto.commit auf false setzen
- commitSync()
 - Blockiert bis success, versucht so lange zu comitten, bis fataler Error auftritt
 - Für "at most once": Aufruf von commitSync() direkt nach poll(), danach Nachrichten verarbeiten
 - Consumer sollte sicher gehen, dass alle Nachrichten die von poll() zurückgegeben wurden verarbeitet werden, sonst könnten Nachrichten verloren gehen
- commitAsync()
 - Sofortige Rückgabe
 - Nimmt optional einen Callback, der ausgelöst wird, wenn der Broker antwortet
 - Hat einen höheren Durchsatz, da der Consumer den nächsten Nachrichtenstapel verarbeiten kann, bevor der Commit zurückkehrt
 - Nachteil: Consumer kann später feststellen, dass die Übertragung fehlgeschlagen ist

Offsets manuell comitten



- Note: Das Offset, was comitted wird (unabhängig ob manuell oder automatisch) ist das Offset der als nächstes zu lesenden Nachricht!
- Default: Kafka speichert Offsets in einer speziellen Topic: __consumer_offsets
- Ggf. möchte man Offsets außerhalb von Kafka speichern (z.B. in Datenbank-Tabelle)
 - Wert lesen, dann seek () verwenden, um beim Starten der Anwendung an die richtige
 Position zu gelangen



Default Partitioning Schema:

- Kafka hashed den Message Key und benutzt das Ergebnis, um die Nachricht einer Partition zuzuordnen
- → Alle Messages mit gleichem Key gehen in die gleiche Partition
- Wenn der Key null ist, wird die Nachricht einer zufälligen Partition zugeordnet (round-robin Algorithmus)
- Dieses Verhalten kann überschreiben werden und ein eigenes Partitioning Schema eingeführt werden



Erstellen eines Custom Partitioners:

- Implementieren des Partitioner Interfaces
 - Enthält die configure, close und partition Methoden
 - partition enthält topic, key, serialized key, value, serialized value und cluster metadata
 - Gibt die Nummer der Partition zurück zu der die Nachricht gesendet wird



Partitioner einbinden:

```
props.put(ProducerConfig.PARTITIONER_CLASS_CONFIG, MyPartitioner.class.getName());
```

Aufgabe 3.1 – Custom Partitioner



- Implementieren Sie einen Custom Partitioner für den Producer aus Aufgabe 3, der Nachrichten sendet, die im Key die Zahlen von 1 bis 100 haben und alle gerade Zahlen zu Partition 0 zuordnet und alle ungeraden Zahlen zu Partition 1 zuordnet
- Implementieren Sie einen Custom Partitioner für den Producer aus Aufgabe 3, der alle Nachrichten mit einem bestimmten Key in eine bestimmte Partition ordnet und alle anderen Nachrichten auf die restlichen Partitionen verteilt



Alternative zu einem Custom Partitioner

Es ist möglich die Partition, in die eine Nachricht gehen soll, zu bestimmen, wenn der ProducerRecord erstellt wird:

```
ProducerRecord<String, String> record = new ProducerRecord<String,
String>("my topic", 0, key, value);
```

→ Ordnet die Nachricht der Partition 0 zu

Diskussion: Welche Methode ist bevorzugt?

Aufgabe 7 – Error handling



- Implementieren Sie error handling für den Consumer in Aufgabe 3
 - Wenn eine Nachricht nicht verarbeitet werden kann, dann wird sie in die dead letter queue geschrieben
 - Der Consumer loggt jeden erfolgreich manuell comitteten offset
 - Der Consumer erhält über einen Kommandozeilenparameter den letzten erfolgreich bearbeiteten Offset und beginnt mit der nächsten Nachricht – verwalten Sie nur eine partition.

- Implementieren sie error handling für den Producer in Aufgabe 3
 - Der Producer loggt den offset einer erfolgreich übermittelten Nachricht.
 Synchronisieren Sie den commit

Einbindung in Spring Boot



Spring for Kafka

- Version 3.1.2
- Basiert auf Kernkonzepten von Spring (z.B. DI, Annotationen, Templates)
- Wird verwendet, um Kafka basierte Messaging Lösungen zu entwickeln
- Bietet Template für High-Level Abstraktion für das Senden von Messages
- Bietet Support f
 ür Message-driven POJOs
- Es kann plain Java zum Versenden und Empfangen von Messages genutzt werden
- Java mit Konfiguration
- Oder am simpelsten mit Spring Boot

Kafka mit Spring Boot - Beispiel



Dependencies

- spring-kafka JAR und alle seine Dependencies
- Am einfachsten mit Maven

```
<dependency>
     <groupId>org.springframework.kafka</groupId>
     <artifactId>spring-kafka</artifactId>
          <version>3.1.2</version>
</dependency>
```

Spring Boot Beispiel:

- Anwendung sendet 3 Nachrichten an ein Topic
- Nachrichten werden empfangen
- Anwendung wird beendet

Spring Boot - Beispiel



Voreinstellungen

- Es wird Group Management benutzt, um Topics und Partitions Consumern zuzuordnen
- Hierfür muss eine Gruppe erstellt werden:

```
spring.kafka.consumer.group-id=foo
```

- Der Container könnte nach dem Verstand der Nachrichten starten.
- Es muss ein Offset eingestellt werden, um sicher zu gehen, dass die neue Consumer Group die Nachrichten auch bekommt:

```
spring.kafka.consumer.auto-offset-reset=earliest
```

Spring Boot - Beispiel



```
@SpringBootApplication
public class Application implements CommandLineRunner {
       public static Logger logger = LoggerFactory.getLogger(Application.class);
       public static void main(String[] args) {
              SpringApplication.run(Application.class, args).close();
      @Autowired private KafkaTemplate<String, String> template;
      private final CountDownLatch latch = new CountDownLatch(3);
      @Override
      public void run(String... args) throws Exception {
            this.template.send("myTopic", "foo1");
            this.template.send("myTopic", "foo2");
           this.template.send("myTopic", "foo3");
            latch.await(60, TimeUnit.SECONDS);
            logger.info("All received");
      @KafkaListener(topics = "myTopic")
      public void listen(ConsumerRecord<?, ?> cr) throws Exception {
            logger.info(cr.toString());
            latch.countDown();
```

Aufgabe 4 – Kafka mit Spring Boot



Aufgabenstellung:

- Erstellen Sie ein Spring Boot Projekt
- Binden Sie die Kafka Bibliotheken ein und konfigurieren Ihren Broker auf Port 9092
- Konsumiren Sie das Topic "Hallo Welt" und geben Sie es auf der Konsole aus
- Senden Sie eine Nachricht an das Topic
- Optional: Führen sie synchrone Requests aus

Aufgabe 4 - Hinweise



- Properties: group-id und auto-offset-reset anpassen
- Wie ein neues Spring-Boot-Projekt anzulegen ist, wird hier beschrieben:
 - https://spring.io/guides/gs/spring-boot/
 - https://start.spring.io
 - https://www.baeldung.com/spring-kafka

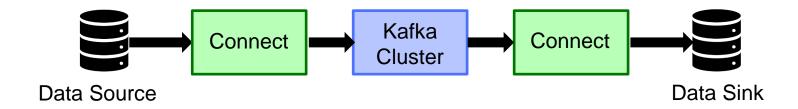


Lektion 5 – Analyse und Transformation

Kafka Connect



- Framework zum Streaming von Daten zwischen Kafka und externen Datensystemen
- Herausgeber: confluent
- Skalierbar, einfach und zuverlässig
- Use cases: Komplette SQL Datenbank zu Kafka streamen, Streamen von Kafka Topics zu Elasticsearch für Indexierung, ...



Kafka Connect vs. Producer/ Consumer API

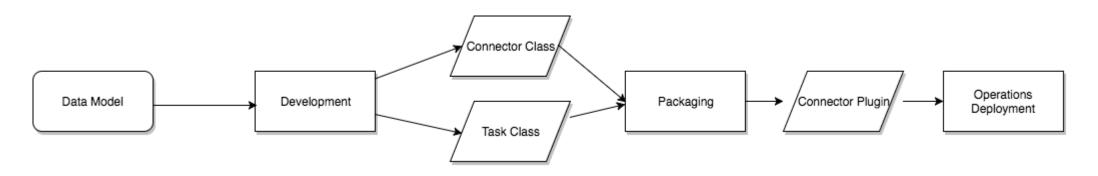


- Im Kern ist Kafka Connect ein Kafka Client der die standard Producer und Consumer APIs benutzt
- Vorteile gegenüber "DIY" Producer und Consumer:
 - Getestete Connectors f
 ür gebr
 äuchliche Datenquellen
 - Unterstützt fault tolerance und automatisches load balancing
 - Keine komplizierte Implementierung, nur configuration files für Kafka Connect nötig
 - Einfach erweiterbar und anpassbar durch Entwickler

Kafka Connect



- Connector: Logical Job bzw. Plugin zum Managen vom Datenaustausch zwischen Kafka und anderem System
 - Connector Sources: Datenübertragung vom externen System zu Kafka (Producer Client)
 - Connector Sinks: Übertragung von Kafka Daten in ein externes System (Consumer Client)
- Task: Connector Jobs werden in Tasks zerlegt, die den Datenaustausch durchführen (stateless)
- Workers: Laufende Prozesse für Connectors und Tasks (standalone vs. distributed)

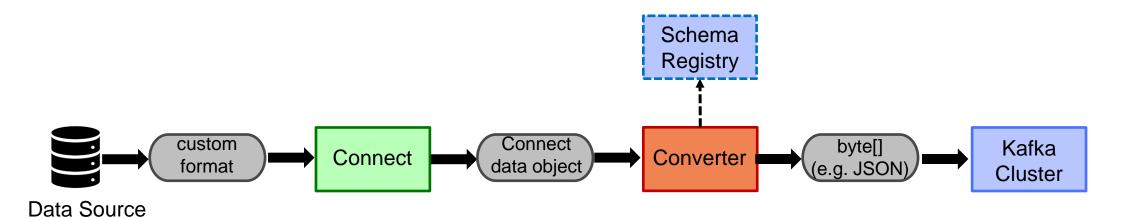


Quelle: https://docs.confluent.io/platform/current/connect/concepts.html#:~:text=handles%20connector%20errors-,Connectors,defined%20in%20a%20connector%20plugin.

Kafka Connect



- Converter: Stellt das Datenformat bereit, das von Kafka gelesen bzw. in Kafka geschrieben wird
 - Konverter zwischen Kafka und Data Source bzw. Data Sink (z.B JSON Converter)
 - Entkoppelt von Connectors: Beliebiger Connector kann für beliebiges Serialisationsformat verwendet werden
- Transforms: Anpassung von Nachrichten von oder zu einem Connector (z.B. Filter)
- Dead Letter Queue: Behandlung von Connector Fehlern (auch für Consumer relevant!)



Kafka Streams



Kafka ist eine Streaming Plattform

- Stream = unbeschränkte, kontinuierlich updatende Datenmenge
- Streams von Datensätzen publishen und abonnieren
 - ähnelt einer Message Queue oder einem Enterprise Messaging System
- Kafka Streams API: Java Bibliothek zum Aufbau verteilter Stream processing applications in Kafka-Clustern
- → Einfache Anwendung
- Speichern von Datensatz-Streams (fault tolerance)
- Verarbeiten von Datensätzen sobald diese auftreten

Kafka Streams



Anwendung von Streams

- Real Time Streaming Datapipelines
 - Zuverlässiger Austausch von Daten zwischen Systemen oder Anwendungen
- Real Time Streaming Anwendungen
 - Auf Daten Streams reagieren oder diese transformieren

Kafka Streams



- Ähnlich zu Spark Streaming, Apache Storm und Co.
- KafkaStreams DSL (map, flatMap, count, ...) vs. low-level Processor API
- Abstraktion: KStream, KTable, ksqlDB

```
public class WordCountApplication {
   public static void main(final String[] args) throws Exception {
       Properties props = new Properties();
        props.put(StreamsConfig.APPLICATION_ID_CONFIG, "wordcount-application");
        props.put(StreamsConfig.BOOTSTRAP_SERVERS_CONFIG, "kafka-broker1:9092");
        props.put(StreamsConfig.DEFAULT_KEY_SERDE_CLASS_CONFIG, Serdes.String().getClass());
        props.put(StreamsConfig.DEFAULT VALUE SERDE CLASS CONFIG, Serdes.String().getClass());
       StreamsBuilder builder = new StreamsBuilder();
       KStream<String, String> textLines = builder.stream("TextLinesTopic");
       KTable<String, Long> wordCounts = textLines
            .flatMapValues(textLine -> Arrays.asList(textLine.toLowerCase().split("\\W+")))
            .groupBy((key, word) -> word)
            .count(Materialized.<String, Long, KeyValueStore<Bytes, byte[]>>as("counts-store"));
        wordCounts.toStream().to("WordsWithCountsTopic", Produced.with(Serdes.String(), Serdes.Long()));
       KafkaStreams streams = new KafkaStreams(builder.build(), props);
        streams.start();
```

PROCESSOR TOPOLOGY

Quelle: https://kafka.apache.org/20/documentation/streams/core-concepts

Quelle: https://kafka.apache.org/documentation/streams/

KStream vs. KTable



KStream

- Abstraktion des Record Streams
- Alle Messages werden als Insert betrachtet

KTable

- Abstraktion des Changelog Streams
- Messages werden als Insert bzw. Update (sog. "Upsert") betrachtet

Beispiel: Summation

- Nachricht 1: {id: 'apple', value: 1}
- Nachricht 2: {id: 'apple', value: 2}
- Ergebnis:
 - KStream: 3 (Summe der Records)
 - KTable: 2 (Update f
 ür Nachricht mit ID 'apple')

Aufgabe 5 – Kafka Streams



Beschreibung

- Kafka-Streams erlauben die "Echtzeit"-Auswertung und Transformation von Daten, die auf Kafka-Topics veröffentlicht werden
- In der Dokumentation wird die Verwendung zur Z\u00e4hlung der Worte im Stream verwendet:
 https://kafka.apache.org/documentation/streams/

Aufgabenstellung:

- Starten Sie das Beispiel aus der Dokumentation
- Zählen Sie die Wörter im Topic "Hello World" auf dem Broker broker-1.k.anderscore.com (Port 9092)

Aufgabe 5 - Hinweise



Hinweise:

- Erzeugen Sie die Projektstruktur wie in Aufgabe 4
- Für Kafka-Streams wird eine weitere Maven Dependency benötigt:

```
<dependency>
<groupId>org.apache.kafka</groupId>
<artifactId>kafka-streams</artifactId>
<version>3.7.0</version>
</dependency>
```

- Die Streams aktualisieren sich, wenn Sie Nachrichten senden.
- Das Codebeispiel schreibt das Ergebnis in den Stream WordsWithCountsTopic, den Sie konsumieren müssen.
- Die Ergebnisse erscheinen innerhalb des eingestellten Intervalls per default müssen Sie ein paar Sekunden warten.

ksqIDB

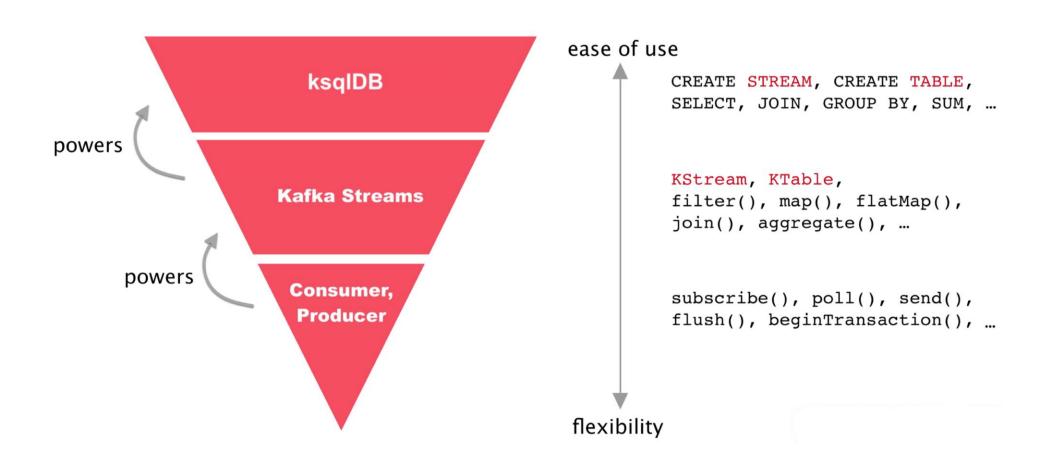


Event Streaming Database

- Hilft beim Erstellen komplexer Stream Processing Anwendungen mit Kafka
- Abfragen, Lesen, Schreiben und Verarbeiten von Daten
- Deklarative Definition von Tabellen, Streams und Konnektoren
- Dynamische Joins
- Lightweight SQL Syntax
- SQL-like Interface
- Runtime: ksqlDB Engine
- Community Component von Confluent
- Alternative / Aufbau zu Kafkas Stream API
- Besser für:
 - Streaming ETL Pipelines
 - Reaktion auf kontinuierliche Real-Time Business Requests
 - Anomalien erkennen







Quelle: https://docs.ksqldb.io/en/latest/concepts/ksqldb-and-kafka-streams

ksqIDB - Beispiel



ksqIDB:

```
CREATE STREAM fraudulent_payments AS
SELECT fraudProbability(data) FROM payments WHERE fraudProbability(data) > 0.8
EMIT CHANGES;
```

Kafka Streams:

```
public class FraudFilteringApplication {
   StreamsBuilder builder = new StreamsBuilder();
   KStream<String, Payment> fraudulentPayments = builder
        .stream("payments-topic")
        .filter((customer ,payment) -> payment.getFraudProbability() > 0.8);
        .to("fraudulent-payments-topic");
   Properties config = new Properties();
   config.put(StreamsConfig.APPLICATION_ID_CONFIG, "fraud-filtering-app");
   config.put(StreamsConfig.BOOTSTRAP_SERVERS_CONFIG, "kafka-broker1:9092");
   new KafkaStreams(builder.build(), config).start();
```

Nach: https://docs.ksqldb.io/en/latest/concepts/ksqldb-and-kafka-streams



Lektion 6 – Broker Operations

Kafka Broker Konfigurieren



Config Files

Jeder Broker hat eine Config Datei

- .property file extension
- Kann in der Datei oder programmatisch angepasst werden
- Nutzt Key / Value Paare

Beispiel:

/usr/local/kafka/config/server.properties

Essentielle Konfiguration



broker.id

- ID des Brokers (unique)
- Bekommt ID automatisch, wenn nicht explizit gesetzt
- Vermeidung von Konflikten zwischen automatisch und explizit gesetzten IDs:

```
reserved.broker.max.id +1
```

log.dirs

- Verzeichnis der log Daten
- Wenn nicht genutzt, wird stattdessen das Verzeichnis in log.dir benutzt

zookeeper.connect

Definiert den Zookeeper connection string

```
hostname:port
```

 Um Verbindung zu anderen Zookeeper Nodes zu ermöglichen, falls eine Verbindung unterbrochen ist: hostname1:port1, hostname2:port2...

Broker Konfiguration



- advertised.host.name
- advertised.listeners
- advertised.port
- auto.create.topics.enable
- auto.leader.rebalance.enable
- background.threads
- compression.type
- control.plane.listener.name
- delete.topic.enable
- host.name
- leader.imbalance.check.interval.seconds
- leader.imbalance.per.broker.percentage
- listeners
- log.flush.interval.ms
- log.flush.offset.checkpoint.interval.ms
- log.flush.start.offset.checkpoint.interval.ms
- log.retention.bytes/hours/minutes/ms
- log.roll.hours/ms
- log.roll.jitter.hours /ms
- log.segment.bytes
- log.segment.delete.delay.ms

- message.max.bytes
- min.insync.replicas
- num.io.threads
- num.network.threads
- num.recovery.threads.per.data.dir
- num.replica.alter.log.dirs.threads
- offsets.metadata.max.bytes
- offsets.commit.required.acks
- offsets.topic.segment.bytes
- port
- queued.max.requests
- quota.consumer.default
- quota.producer.defaults
- replica.fetch.min.bytes
- request.timeout.ms
- socket.receive.buffer.bytes
- socket.request.max.bytes
- transaction.max.timeout.ms
- unclean.leader.election.enable
- zookeeper.connection.timeout.ms
- zookeeper.max.in.flight.requests
- zookeeper.session.timeout.ms
- Gesamte Liste: https://kafka.apache.org/documentation/#brokerconfigs

Updaten der Broker Konfiguration



Live Update

Einige Configs können ohne Broker Restart geändert werden

- ready-only: Nur mit Neustart
- per-broker: Dynamisch für jeden Broker einzeln
- cluster-wide: Dynamisch gesamtes Cluster oder einzelne Broker

Beispiel Live Update:

- Broker id 0
- Anzahl der Log Cleaner Threads

> bin/kafka-configs.sh --bootstrap-server localhost:9092 --entity-type brokers --entity-name 0 -- alter --add-config log.cleaner.threads=2

Topics verwalten



- Default: Topics werden automatisch erstellt, wenn sie das erste mal von einem Client benutzt werden
 - Replication factor ist 1, eine einzelene Partition
 - In production environments: Ggf. auto.create.topics.enable deaktivieren
- Topic manuell erstellen (vgl. Aufgabe 2):

```
bin/kafka-topics.sh --bootstrap-server localhost:9092 --create --topic myTopic --
partitions 2 --replication-factor 1
```

Topic ändern:

```
bin/kafka-topics.sh --bootstrap-server localhost:9092 --alter --topic myTopic --
partitions 3 --replication-factor 2
```

Achtung: Ändern der Anzahl an Partitionen kann zu Problemen in der Anwendungslogik führen!

Topics verwalten



Topic löschen:

```
bin/kafka-topics.sh --bootstrap-server localhost:9092 --
delete --topic myTopic
```

- Alle Broker müssen delete.topic.enable auf true gesetzt haben
 - Default ist false, falls es nicht gesetzt ist, wird Löschkommando ignoriert
- Alle Broker müssen laufen, damit der Löschvorgang erfolgreich ist

Topics verwalten: Einstellungen



Topic Level Einstellungen: Beispiele

- cleanup.policy
- compression.type
- delete.retention.ms
- file.delete.delay.ms
- flush.messages
- flush.ms
- follower.replication.throttled.replicas
- index.interval.bytes
- leader.replication.throttled.replicas
- min./max.compaction.lag.ms
- max.message.bytes
- message.format.version
- message.timestamp.difference.max.ms

- message.timestamp.type
- min.cleanable.dirty.ratio
- min.insync.replicas
- preallocate
- retention.bytes
- retention.ms
- segmentet.bytes
- segment.index.bytes
- segment.jitter.ms
- segment.ms
- unclean.leader.election.enable
- message.downconversion.enable

Gesamte Liste: https://kafka.apache.org/documentation/#topicconfigs

Topics konfigurieren, anlegen und verwalten



Topic Konfiguration

- Relevante Konfiguration
 - Server Default
 - Per-Topic Override

Override kann beim Erstellen eines Topics in der Kafka Shell eingestellt werden

- --config
- Eine oder mehrere Einstellungen

Topics verwalten



Overrides können auch später mit add-config konfiguriert werden

Im folgenden Beispiel wird die max.message.bytes upgedated:

Overrides überprüfen mit --describe:

```
> bin/kafka-configs.sh --bootstrap-server localhost:9092 --entity-type topics --entity-name my-topic
--describe
```

Override entfernen mit --alter --delete-config:



Lektion 7 – Best Practices

Best Practices



Producer

- Automatische Retries möglichst abschalten (Reordering)
- acks = all für "Konsistenz über Verfügbarkeit" (vgl. CAP Theorem)
- Mehrere Bootstrap Server angeben (Fehlertoleranz)

Consumer

- Nicht zu viele Daten auf einmal pollen (Netzwerklast, OutOfMemoryError)
- Auto-Commit beachten und möglichst abschalten
- Topics mit Consumer Offsets richtig konfigurieren (Compaction und Deletion!)
- At-least-once-Semantik meist beste Wahl
- Mehrere Bootstrap Server angeben (Fehlertoleranz)

Nach: https://media.ccc.de/v/froscon2018-2213-apache_kafka_lessons_learned

Best Practices



Broker

Defaults setzen und bei Bedarf überschreiben (Fehlervermeidung)

Topics

- Deletion vs. Compaction fachlich entscheiden
- retention.ms wirkt nur bei Deletion, max.cleanable.dirty.ratio nur bei Compaction
- Automatisiert anlegen (z.B. Skript)
- Richtwert: ~ 10 bis 30 Partitionen pro Topic

Streams

Dead Letter Queue vorsehen (z.B. Topic)

Nach: https://media.ccc.de/v/froscon2018-2213-apache_kafka_lessons_learned



Lektion 8 – Ausblick

Microservice Architektur

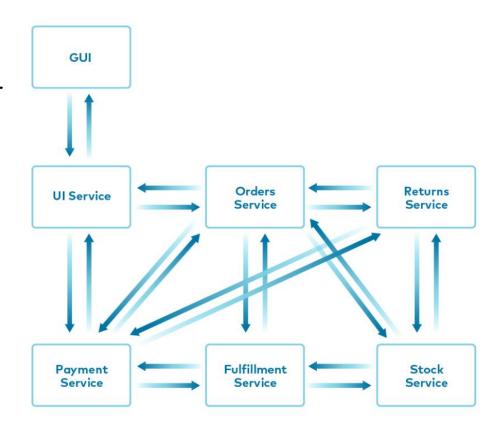


Microservices:

- Fachlicher Schnitt (Bounded Contexts)
- Weniger Verantwortlichkeiten → leichter austauschbar
- Potential f
 ür bessere Skalierbarkeit und Fehlertoleranz
- Lose Kopplung zwischen Services

Beispiel:

- Simples Business System in Microservice Architektur
- Asynchrone Kommunikation über Messages
- Eventbasiert



Quelle: WP Microservices in the Apache Kafka Ecosystem Confluent 2017 $\,$

Microservices mit Kafka

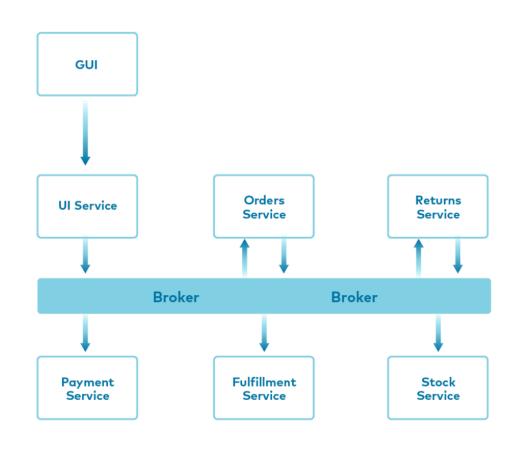


Microservice Environment

- Event-basiert
- Request / Response basiert
- Hybrider Ansatz:
 - Service Discovery
 - Synchrone Vorgänge
 - Asynchrone, Event-basierte Flows
 - Anpassbarkeit
 - Skalierbarkeit

Praxisbeispiel:

- Asynchroner eMail Service mit Kafka Streams
- Order und Payment Stream joinen
- Ergebnis zu einem Lookup Table von Kunden joinen
- E-Mail zu jedem resultierenden Touple versenden



Quelle: WP Microservices in the Apache Kafka Ecosystem Confluent 2017

Apache Avro - Serialization



Apache Avro

- Data Serialization System (& RPC, Container)
- Vergleichbar mit: Thrift, Protocol Buffers
- Aktuell: 1.11.1
- Bindings: Java, Python, C, C++, C#, JavaScript, ... (3rd party)
- Teil des Hadoop Projekts
- Serialization Format für persistente Daten
- Wire Format für Nodes und Clients

Schema für Daten in JSON

- Getrennt von den Nutzdaten
- Code-Generatoren (code-first, contract-first)
- Gemeinsames Schema für verschiedene µServices



Apache Avro – Beispiel für Schemata



```
{
  "namespace": "example.avro",
  "type": "record",
  "name": "User",
  "fields": [
        {"name": "name", "type": "string"},
        {"name": "favorite_number", "type": ["int", "null"]},
        {"name": "favorite_color", "type": ["string", "null"]}
]
}
```

Quelle: https://en.wikipedia.org/wiki/Apache_Avro

Apache Avro – Integration mit Kafka



Confluent Schema Registry (OpenSource)

- Historisierung, Java & RESTful API, Migration
- Kein Transport mit den Daten (Performance)
- Persistenz: Kafka-Topic
- Command Line Client

Avro als wire-format?

- Einheitliches Schema für Daten zwischen Systemen
- Pro:
 - Integration (confluent platform)
- Contra:
 - XML & JSON deutlich weiter verbreitet



Aufgabe 6 - Avro



Beschreibung:

- Austausch von Nachrichten zwischen zwei Services über Kafka
- Serialisierung und Deserialisierung über Avro mit JSON-Schemata
- Generierung von Java Klassen aus Metadaten
- Die Confluent Platform enthält eine Avro Schema Registry, mit der Schemas unternehmensweit verwaltet werden können.
- Die OpenSource-Ausgabe der Confluent-Platform ist auf broker-2.k.anderscore.com installiert.
- Confluent bietet ein Maven Plug-In zum Schema-Download an:
 https://docs.confluent.io/platform/current/schema-registry/develop/maven-plugin.html
- Weitere Infos: https://docs.confluent.io/current/schema-registry/docs

Aufgabe 6 - Avro



Aufgabenstellung:

- Unter folgendem Link liegt ein Producer, welcher Personendaten (SteuerID, Name, Vorname) sendet:
 https://github.com/anderscore-gmbh/kafka-24.03.1/tree/main/Aufgabe6-Producer
- Implementieren Sie einen Consumer, welcher die Daten deserialisiert und auf der Konsole ausgibt.

Schemata:

http://broker-2.k.anderscore.com:8081/subjects

http://broker-2.k.anderscore.com:8081/schemas/ids/1

http://broker-2.k.anderscore.com:8081/schemas/ids/2

Aufgabe 6 - Hinweise



Hinweise:

- Verwenden Sie den Consumer aus Aufgabe 4 als Vorlage
- Die Schemata k\u00f6nnen Sie aus dem Producer \u00fcbernehmen oder aus der Registry laden.
- Beachten Sie die pom.xml des Producers zu Abhängigkeit und Generator-Konfiguration
- Simulieren Sie einen Tippfehler: Benennen Sie das Feld firstName in fristName um und generieren Sie den Avro-Code für den Consumer erneut. Was passiert beim Start?
- Tipp: Ändern Sie die Consumer Group bei Bedarf
- Ein Beispiel für den Consumer finden Sie unter:
 - https://github.com/anderscore-gmbh/kafka-24.03.1/tree/master/Aufgabe6-Consumer

Kafka und Testing



Topics und Partitions

- Senden von Messages an einen Topic, Auswerten der recordMetadata
- Konsumieren eines Topics, Validieren der Messages
- Command Line, Kafka Client API (low-level)

Producer und Consumer

- Klassische Unit Tests mit Mocks
- Programmatische Integration Tests mit EmbeddedKafkaCluster
- Programmatische Integration Tests mit Spring Boot
- Deklarative Integration Tests mit Zerocode

Microservices

End-to-end Tests mit Testcontainers

Kafka und Testing



Beispiel: Spring Boot

```
@SpringBootTest
@DirtiesContext
@EmbeddedKafka(partitions = 1, brokerProperties = { "listeners=PLAINTEXT://localhost:9092", "port=9092" })
class EmbeddedKafkaIntegrationTest {
   @Autowired
   private KafkaConsumer consumer;
   @Autowired
   private KafkaProducer producer;
   @Value("${test.topic}")
   private String topic;
   @Test
   public void givenEmbeddedKafkaBroker_whenSendingtoSimpleProducer_thenMessageReceived()
      throws Exception {
        producer.send(topic, "Sending with own simple KafkaProducer");
        consumer.getLatch().await(10000, TimeUnit.MILLISECONDS);
        assertThat(consumer.getLatch().getCount(), equalTo(0L));
        assertThat(consumer.getPayload(), containsString("embedded-test-topic"));
```

Quelle: https://www.baeldung.com/spring-boot-kafka-testing

Kafka und Testing



Weiterführende Literatur zum Thema

- https://dzone.com/articles/a-quick-and-practical-example-of-kafka-testing
- https://github.com/authorjapps/zerocode/wiki/Kafka-Testing-Introduction
- https://medium.com/test-kafka-based-applications/https-medium-com-testing-kafka-based-applications-85d8951cec43
- https://github.com/apache/kafka/tree/trunk/streams/src/test/java/org/apache/kafka/streams/integration/utils
- https://www.baeldung.com/spring-boot-kafka-testing
- https://www.testcontainers.org/modules/kafka