

Willkommen zum Seminar



© 2024 anderScore GmbH

Apache Kafka - Event Streaming mit Java

Jan Lühr (M.Sc. Computer Science)

- Senior Software Engineer
- Schwerpunkte
 - Pragmatic Architect
 - Integration und Migration
 - Web / Mobile Engineering
 - Clean Code
 - Trainings, Artikel, Vorträge
 - Network- and Security-Techniques
 - IT-Trainer
- Java, Spring, JEE, Kafka, Android, Microservices,...



Individuelle Anwendungsentwicklung - Java Enterprise, Web, Mobile

- seit 2005 ♦ in Köln ♦ für alle Branchen ♦
- nach Aufwand & zum Festpreis
- ✓ Digitalisierung / Prozesse / Integration
- ✓ Migration
- ✓ Neuentwicklung
- ✓ Notfall / kritische Situation
- ➔ pragmatisch, zielgerichtet, zuverlässig



Kompletter SW Life Cycle

- Projektmanagement / agile Methodik
- Anforderungsanalyse
- Architektur & SW-Design
- Implementierung & Testautomation
- Studien & Seminare



... und für Sie? Sprechen Sie uns an!

Apache Kafka – Event Streaming mit Java

07.03. – 08.03.24

Jan Lühr



Begrüßung

1. Einführung
2. Paradigmen und Funktionsweise
3. Komponenten
4. Implementierung von Clients
5. Analyse und Transformation
6. Broker Operations
7. Best Practices
8. Ausblick

Lektion 1 - Einführung

- Workshop
 - Einführung in grundlegende Kafka-Konzepte
 - Überwindung von Einstiegshürden
 - Funktionen und Features mit Aufgaben erarbeiten

- Zielgruppe
 - Softwareentwickler:innen, Architekt:innen und DevOps mit guten Java-Kenntnissen

- Voraussetzungen
 - Gute Java Kenntnisse
 - Sicherheit im Umgang mit einer IDE (z.B. IntelliJ)

Beginn	09:00 Uhr
Kaffeepause	ca. 10:30 Uhr
Mittagspause	12:00 bis 13:00 Uhr
Ende	16:00 Uhr

- Video-Konferenz über Zoom
 - Bildschirmfreigabe für Folien
 - Lautsprecher + Mikrofon benötigt, Kamera empfehlenswert
 - Zugangsdaten, um Rechner per Web-Browser zu erreichen:

<https://connect.gfu.cloud/>

Benutzername: 55842

- Entwicklung: Remote Desktop Protocol (RDP) zur GFU
 - Praktische Übungen
 - Ubuntu VM
 - Aufschaltung über Zoom möglich

- Material auf GitHub

<https://github.com/anderscore-gmbh/kafka-24.03.1>

Vereinbarungen

- Pausen
 - Gemeinsam zu vorgegebenen Zeiten
 - Individuell während der Übungen
- Erreichbarkeit Dozent
 - Zoom (Chat, Mikrofon)
 - E-Mail
- Regeln
 - Mikrofon möglichst aus (Hintergrundgeräusche)
 - Bei Fragen: "Hand heben" oder Chat
 - Wenn Übung fertig, selbst in Hauptsession zurückkehren

- Kafka Quickstart
 - <https://kafka.apache.org/quickstart>
- Kafka Cheat Sheet
 - <https://github.com/lensesio/kafka-heat-sheet>
- Kafka E-Book
 - <https://www.confluent.io/resources/kafka-the-definitive-guide>

Jetzt sind Sie dran!

- Name
- Vorwissen
- Erwartungen
- Themenwünsche



- Kafkacat
- JDK 17
- Maven
- Entwicklungsumgebung (z.B. IntelliJ)
- Docker Desktop oder Docker Engine

Aufgabenstellung:

- Installieren Sie `kafkacat` bzw. `kcat` auf Ihrem System
- Senden Sie eine Nachricht an `broker-1.k.anderscore.com:9092` – Topic: `HelloWorld`
- Konsumieren Sie alle Nachrichten des Topics und geben Sie diese aus

Hinweise:

- Ubuntu / Debian (ggf. vorinstalliert): `apt-get install kafkacat`
- Nachricht senden:
`echo "Hallo Welt" | kafkacat -b broker-1.k.anderscore.com -t HelloWorld`
- Nachricht konsumieren:
`kafkacat -b broker-1.k.anderscore.com -t HelloWorld`

Aufgabe 0 – Hello World mit kafka-console-producer/consumer

Kafka Archiv herunterladen und entpacken:

https://dlcdn.apache.org/kafka/3.7.0/kafka_2.13-3.7.0.tgz

Nachricht in das Topic schreiben:


```
$ bin/kafka-console-producer.sh --topic HelloWorld --bootstrap-server broker-1.k.anderscore.com:9092  
This is my first event  
This is my second event
```

Nachricht aus Topic auslesen:

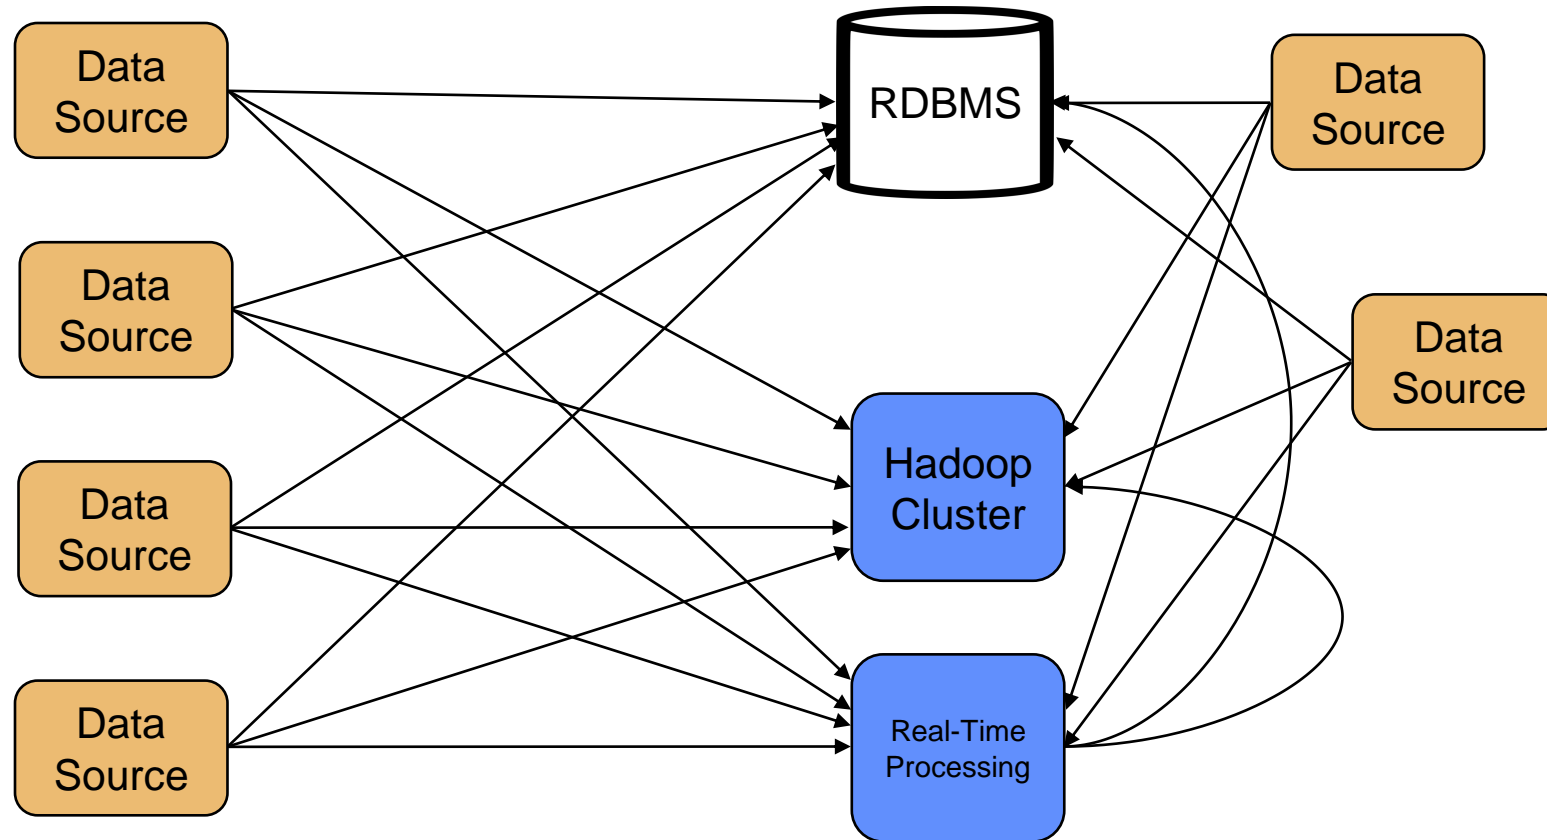
```
$ bin/kafka-console-consumer.sh --topic HelloWorld --from-beginning --bootstrap-server broker-1.k.anderscore.com:9092
```

Lektion 2 - Paradigmen und Funktionsweise von Kafka

Einfache Datenverteilung:




Komplexe Datenverteilung:



- Motivation
 - Komplexe Datenverteilung bewältigen
 - Batch-Verarbeitungsprozess verbessern
 - Zeitnahe Verarbeitung ermöglichen


- Ziele von Kafka
 - Pipelines vereinfachen
 - Data Stream Handling


- Ansatz
 - Stream Data Platform: Stream Processing statt Batch Processing
 - Middleware für persistente Logs / Streams
 - Ähnlich zu MQTT und Message Queuing





- Enstanden auf LinkedIn (2010)
 - Teil der Core-Architektur
 - 1.4 Milliarden Nachrichten pro Tag
- Genutzt von:
 - IBM, zalando, airbnb, Cisco, Netflix, Paypal, Twitter...
- Use Cases:
 - Event Verarbeitung (*quasi realtime*)
 - Log Aggregation
 - Metriken & Analyse
 - Messaging / μ Service Kommunikation
- Keine Realtime- bzw. Echtzeitverarbeitung
(Werbeversprechen; im Sinne von Reordering Queues)

- Aktuell: Version 3.7.0
- Release Notes der Versionen unter
https://downloads.apache.org/kafka/3.7.0/RELEASE_NOTES.html
- Upgrade auf neue Version und Changelog unter
https://kafka.apache.org/blog#apache_kafka_370_release_announcement











Two Generals Problem





Definition:

Eine Operation, welche mehrfach hintereinander ausgeführt das gleiche Ergebnis wie bei einer einzigen Ausführung liefert.

<https://de.wikipedia.org/wiki/Idempotenz>

Was passiert bei einem Fehler?

- **At least once**
 - Mindestens ein Mal: Risiko von Duplikaten
- **At most once**
 - Maximal ein Mal: Kein Neuversuch beim Fehlschlag
- **Exactly once**
 - Genau ein Mal: In Praxis schwer zu erreichen


At Least Once



Situation: Druckfehler / Toner leer: Ausdruck zu hell!

1. Fehler wird behoben
2. Alle Seiten in der Warteschlange werden gedruckt
3. ... sehr viel Papier

At Most Once



Situation: Druckfehler / Toner leer: Ausdruck zu hell!

1. Fehler wird behoben
2. Keine Seite in der Warteschlange wird gedruckt
3. ... hin und her laufen.

Exactly Once



Situation: Druckfehler / Toner leer: Ausdruck zu hell


1. Fehler wird behoben
2. Genau die zu hellen Seiten werden gedruckt
3. ... Perfekt 😊

Woher weiß der Drucker, welche Seiten zu hell sind?

- Idee: Seitennummer am Bedienfeld eingeben
- Im Allgemeinen: schwer umsetzbar
- Idee *auch bei Kafka*: Stand der Verarbeitung im Ergebnis speichern

<https://www.confluent.io/de-de/blog/exactly-once-semantics-are-possible-heres-how-apache-kafka-does-it/>

Publish and Subscribe



Active Polling

Konzept:

- Es wird nicht automatisch an alle Subscriber gesendet (vgl. Observer Pattern)
- Subscriber senden zyklisch Anfragen
- Existiert neuer Inhalt, wird er als Antwort zurückgeliefert

Event Sourcing

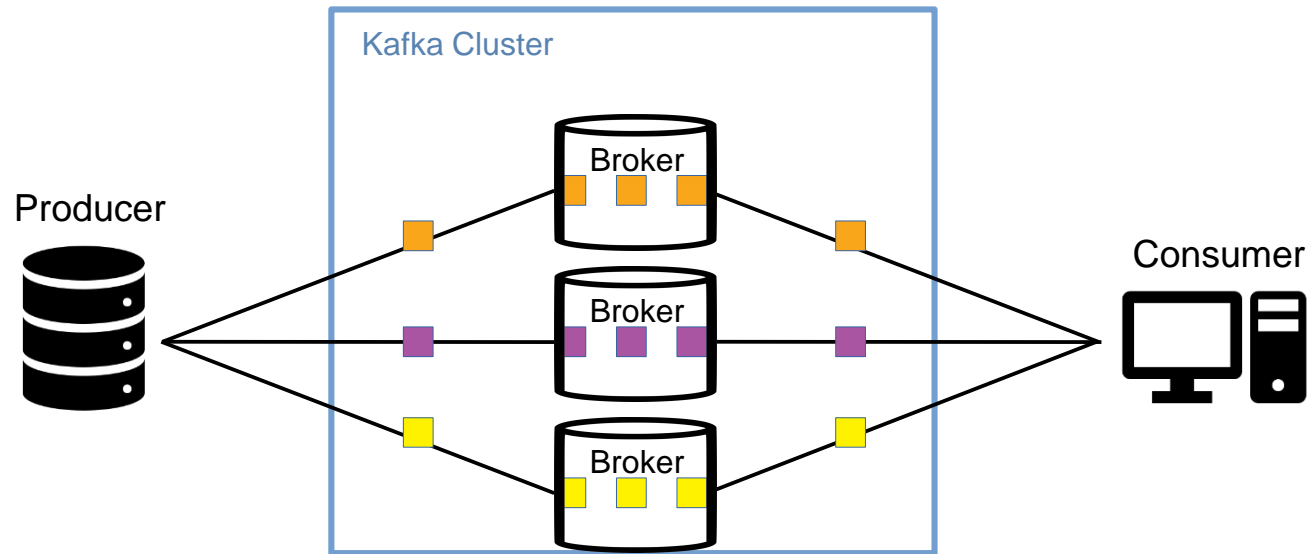
Konzept:

- Veränderung eines Zustandes = Event
- Nach Empfang neuer Daten werden alte nicht gelöscht
- Neue Events werden kontinuierlich im Event Store an alte angehängt
- Kafka: Retention Policy

Zweck:

- Kein Informationsverlust
- Analysemuster
- Macht Kafka zu einem Hybrid aus Datenbank und Messaging System

- *Producer* senden Nachrichten an den Kafka-Cluster
- *Consumer* lesen Nachrichten vom Kafka-Cluster
- *Broker* sind die Speicher- und Nachrichtenkomponenten des Kafka-Clusters
- Die kleinste Einheit an Daten in Kafka sind *Messages*, sie werden gruppiert in sogenannten *Topics*



Aufgabenstellung Kafka Quickstart

- Laden Sie das aktuelle Kafka Release herunter <http://kafka.apache.org/quickstart>
- Nutzen Sie KRaft
- Starten Sie das Kafka Environment in der Linux Shell
- Legen Sie ein Topic an
- Schreiben Sie einige Nachrichten in das Topic
- Lesen Sie die Nachrichten aus dem Topic aus

Topic erzeugen

```
$ bin/kafka-topics.sh --create --topic HelloWorld --bootstrap-server localhost:9092
```

Topic prüfen

```
$ bin/kafka-topics.sh --describe --topic HelloWorld --bootstrap-server localhost:9092
```

```
Topic: quickstart-events TopicId: NPmZHyhbR9y00wMglMH2sg PartitionCount: 1
```

```
ReplicationFactor: 1 Configs:
```

```
Topic: quickstart-events Partition: 0      Leader: 0      Replicas: 0 Isr: 0
```

Was ist Confluent Platform?

- Die Confluent Platform ist eine umfassende Streaming-Plattform, die kontinuierliche Echtzeitdaten einfach zugänglich macht und entwickelt wurde, um die Anwendungsentwicklung und -vernetzung zu beschleunigen.
- Confluent Platform ist eine herunterladbare Software, die alle Kafka-Anwendungsfälle abdeckt und zusätzliche Funktionen und APIs bietet.
- Durch die Integration von historischen und Echtzeitdaten in eine zentrale Wahrheitsquelle ermöglicht Confluent die Entwicklung moderner, ereignisgesteuerter Anwendungen mit voller Skalierbarkeit und Zuverlässigkeit.
- Die Plattform erleichtert Transformationen durch Stream-Verarbeitung, vereinfacht unternehmensweite Operationen und erfüllt strenge architektonische Anforderungen.
- <https://docs.confluent.io/platform/current/platform-quickstart.html>

Voraussetzungen

- Docker Desktop oder Docker Engine ist installiert
- Docker läuft, prüfen mit `docker info`

Aufgabenstellung

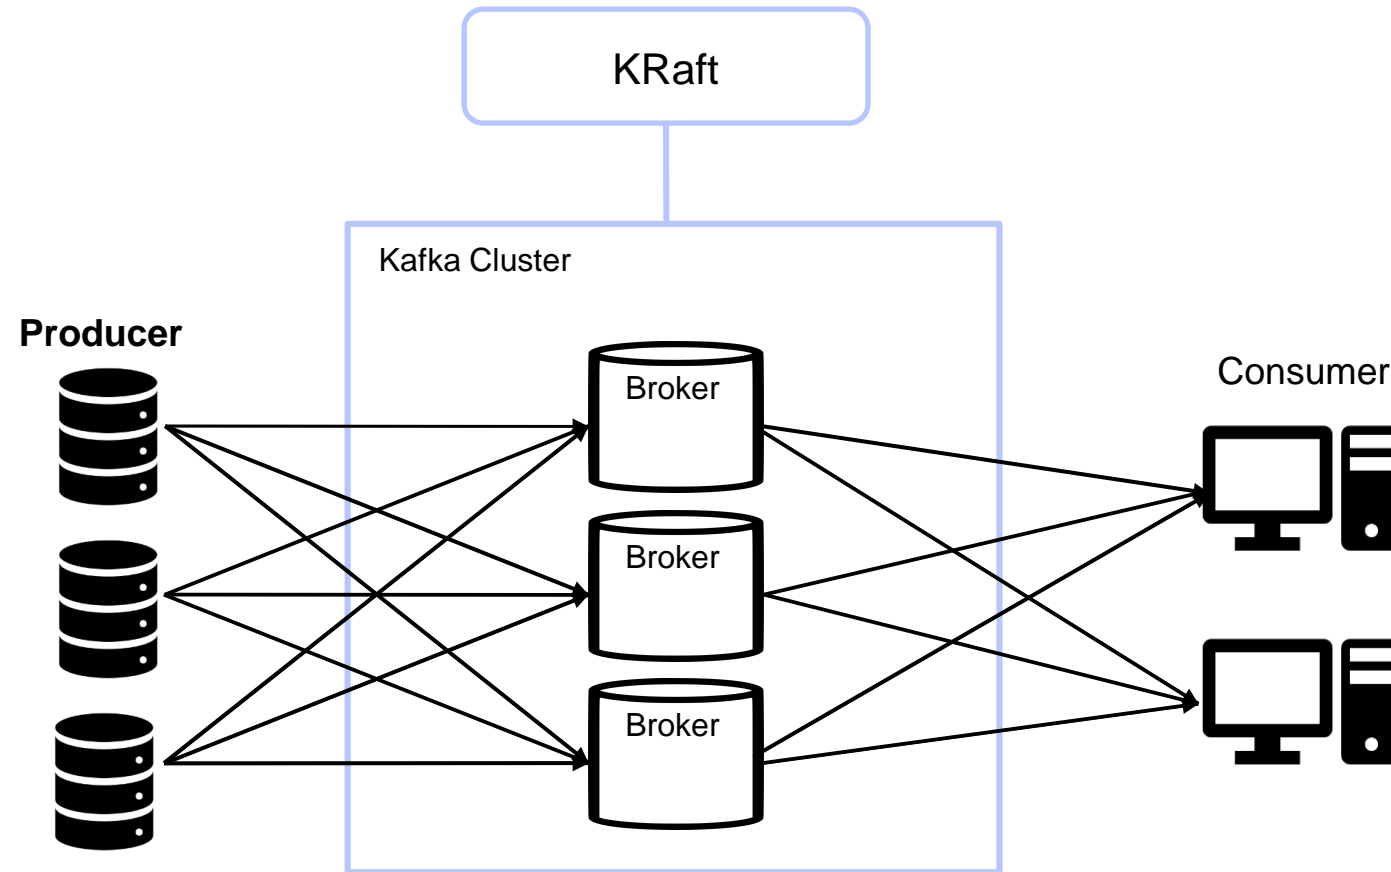
- Starten Sie den kafka broker mit Confluent
- Legen Sie ein Topic an
- Initialisieren Sie einen Producer, der eine „Hello World“ Nachricht in das Topic schreibt
- Initialisieren Sie einen Consumer von einem anderen Kafka Terminal, welcher Nachrichten aus dem Topic liest


Materialien

- Quickstart <https://docs.confluent.io/platform/current/platform-quickstart.html>

Lektion 3 – Komponenten

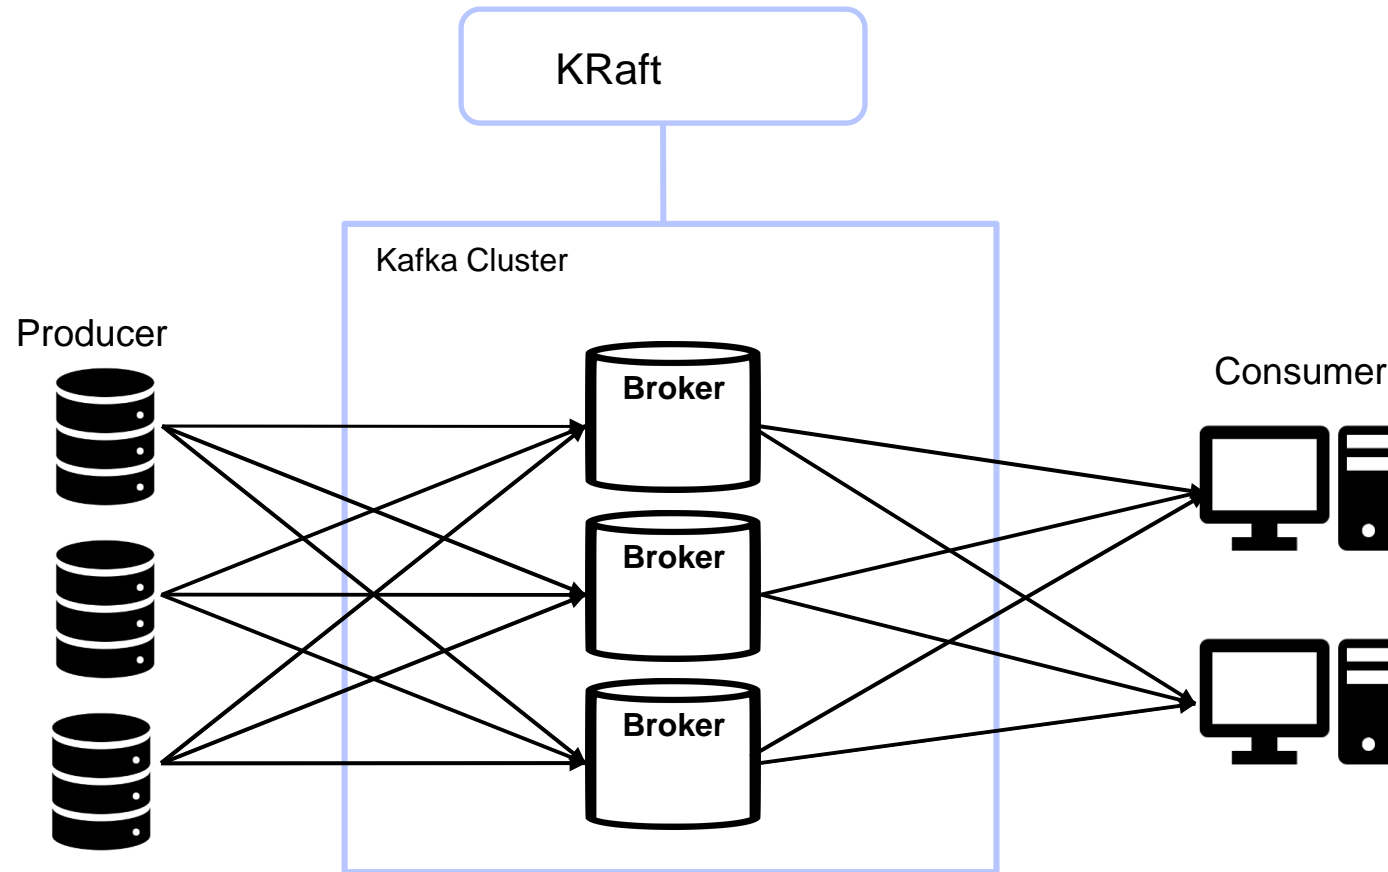
- **Producer**
- **Broker**
- **Consumer**
- **KRaft**







- Teil einer Anwendung
- Senden Daten an den Kafka Cluster
- Sharding der Messages (Partitionierung)
 - Über Hash Key oder Round Robin
 - Alternativ auch über eigene Strategie
 - Load Balancing: Verteilung der Last über Broker
 - Semantic Partitioning: User spezifischer Key
- Anbindung über:
 - Nativ: Java, C/C++, Python, Go, .Net, JMS
 - REST (Confluent)
- Zusätzlich existieren Implementierungen für viele andere Sprachen

- Producer
- **Broker**
- Consumer
- KRaft



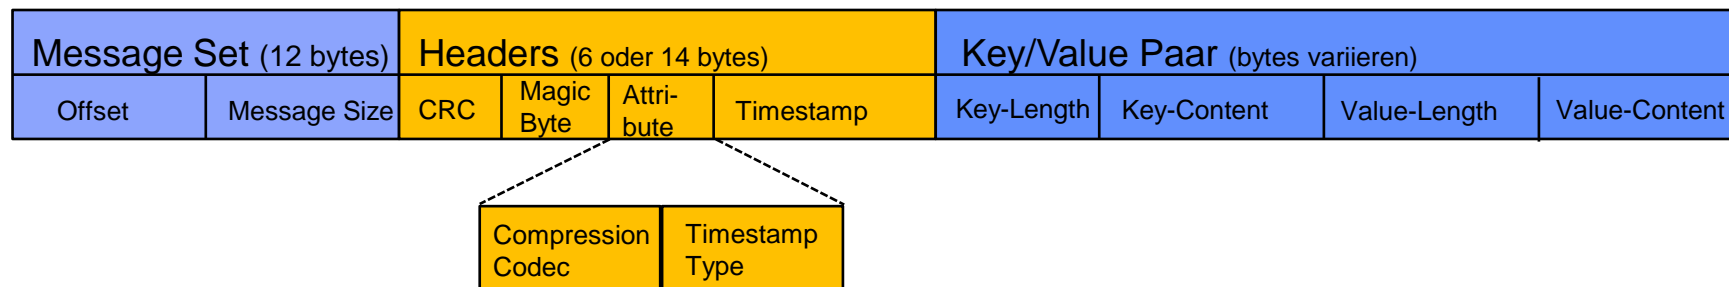


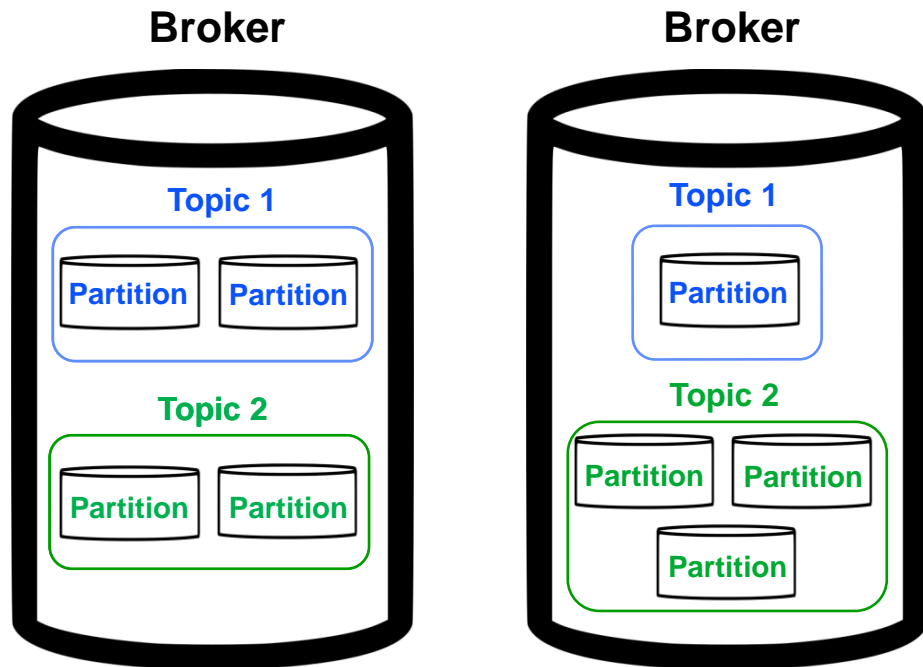
- Server Prozess (aktiv)
- Storage und Messaging Komponente
- Empfängt und speichert Nachrichten
- Message-Speicher: Direkt auf Hard Disk (Zero Copy)
- Existiert mehrfach pro Cluster
- Bedient Client Prozesse
- Weist Clients individuelle Offsets zu
- Verwaltet mehrere Topics und Partitionen



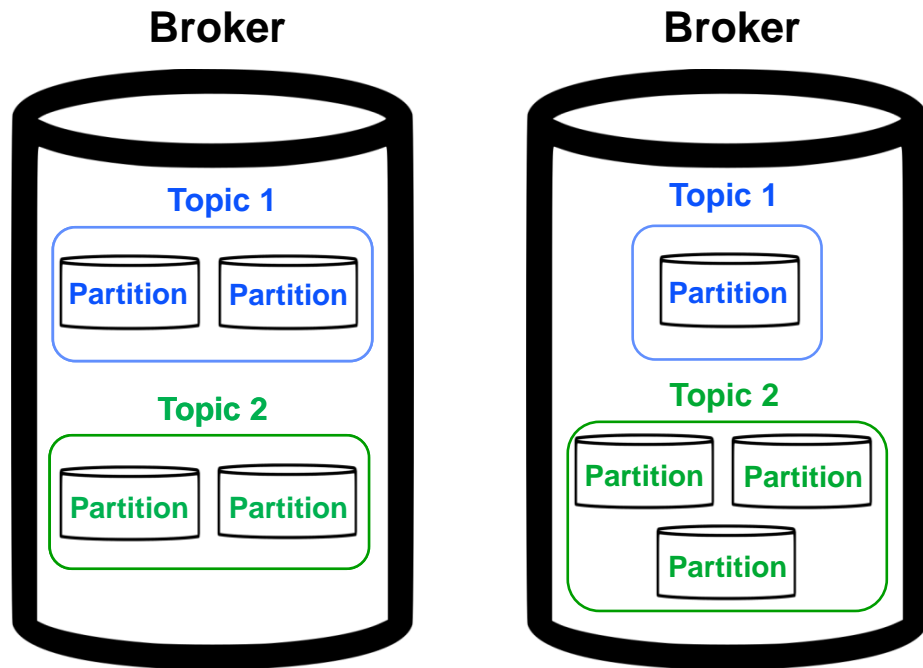
- Logischer Name eines Streams
- Gruppiert Messages
- „Beliebig“ viele pro Cluster
- Von Kafka verwaltet
- Von Entwickler(in) administriert
- Cleanup-policy: compact vs. delete
- Segment Size: head vs. tail
- Besteht aus mehreren Partitions

- Eine Message ist ein **Key-Value** Paar; Key und Value können von beliebigem Datentyp sein
- Messages enthalten Daten und Metadaten:
 - Key/Value Paar
 - Offset
 - Timestamp
 - Compression type




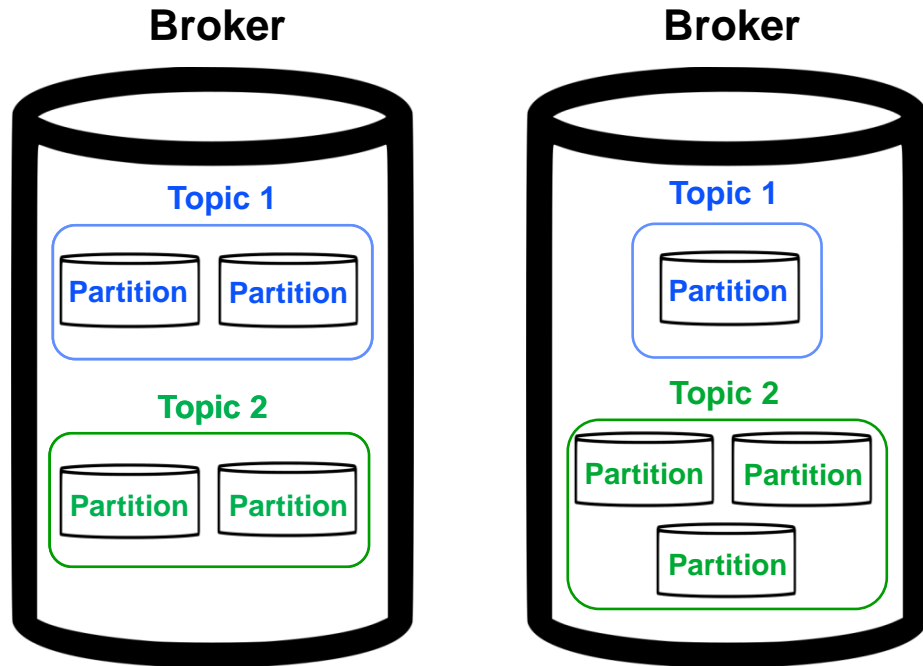


- Jede Partition enthält eine Teilmenge der Nachrichten einer Topic; üblich: Message Key zur Zuordnung einer Partition
- Lokale Ordnung innerhalb einer Partition, append-only
- Identifier innerhalb einer Partition: Offset einer Message, wachsend
- Replication zwischen Brokern möglich → Fault Tolerance



- Jede Partition enthält eine Teilmenge der Nachrichten einer Topic; üblich: Message Key zur Zuordnung einer Partition
- Lokale Ordnung innerhalb einer Partition, append-only
- Identifier innerhalb einer Partition: Offset einer Message, wachsend
- Replication zwischen Brokern möglich → Fault Tolerance






- Jede Partition enthält eine Teilmenge der Nachrichten einer Topic; üblich: Message Key zur Zuordnung einer Partition
- Lokale Ordnung innerhalb einer Partition, append-only
- Identifier innerhalb einer Partition: Offset einer Message, wachsend
- Replication zwischen Brokern möglich → Fault Tolerance
- Clients lesen nur vom Leader
- Head: in-memory
- Tail: persistent (Deletion & Compaction)
- Drift konfigurierbar

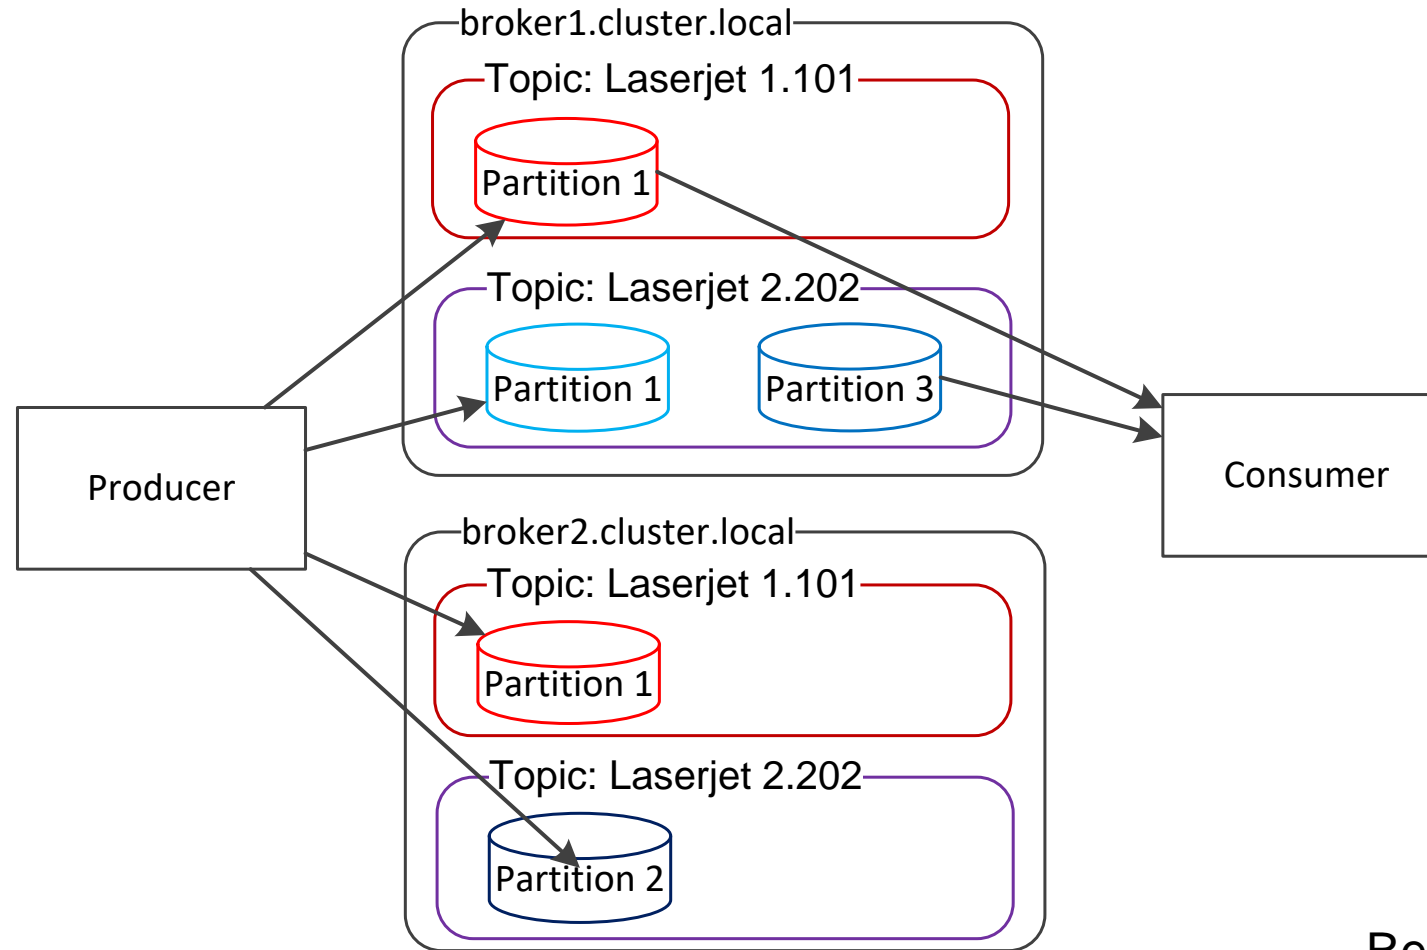
Aufbau:

- Cluster besteht aus 1...n Brokern
- Ein oder mehrere Producer können in eine oder mehrere Topics schreiben
- Messages einer Topic sind in über 1...m Partitions in verschiedenen Brokern verteilt

Anatomy of a Topic




Partitionen: Printer Beispiel




Repliziert: Laserjet 1.101
Sharding: Laserjet 2.202

- Producer
- Broker
- **Consumer**
- KRaft




- Abruf von Messages via **pull, single-threaded**
- **Consumer Offset**
 - Nächste zu lesende Nachricht
 - Pro Consumer und Partition
 - Speicher: spezielles internes Topic (oder extern)
 - Commit: automatisch (default: 5 sec – Obacht!) oder manuell
- **Semantik:**
 - At least once: Nachricht bearbeiten *danach* Commit
 - At most once: Commit, *danach* Nachricht bearbeiten
 - Exactly once: Offset im Zielsystem speichern (lokale Transaktion)
- **Verschiedene Consumer**
 - Gleichzeitiges Lesen möglich
 - Default: Alle Nachrichten im Topic an alle Consumer
 - Spezialfall: *Consumer Group*

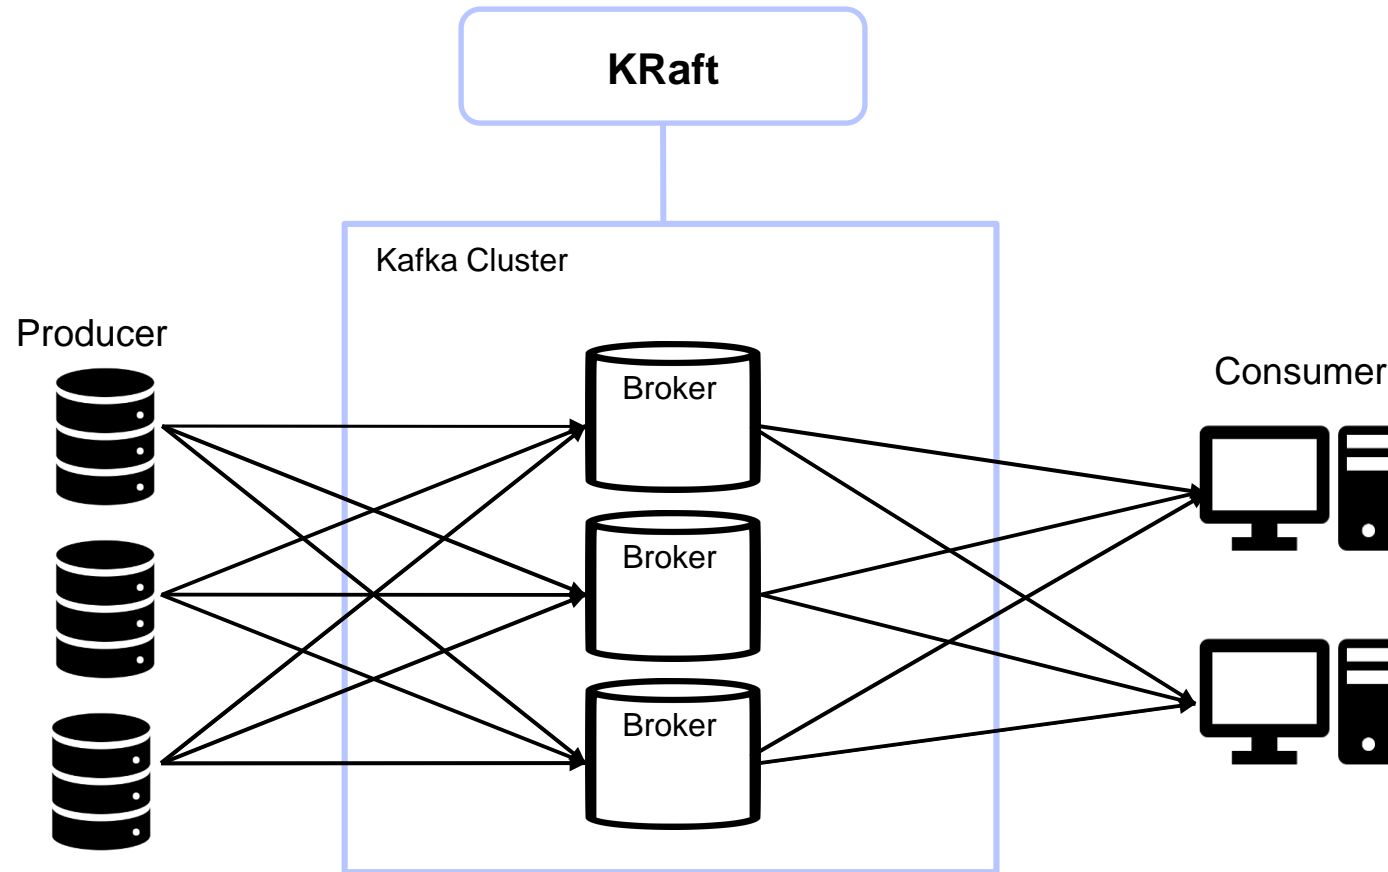


<https://docs.confluent.io/platform/current/clients/consumer.html>

- Gruppierung: **Consumer Group**
 - Mehrere Consumer zusammenfassen → Consumer Group
 - Jeder Consumer bearbeitet nur **Subset** der Partitionen
 - Eindeutige Group ID
 - Jeder Consumer in einer Group braucht eigene Partition
 - Ein Subset von Partitionen
 - Automatisches Error-Handling & Load-Balancing
- Scaling
 - Maximal ein Consumer pro Partition pro Gruppe
 - **#Consumer ≤ #Partitions**
 - #Partition ändern: Schwer möglich
 - Besser: Neues Topic bei Release-Wechsel (API-Versionierung)




- Producer
- Broker
- Consumer
- **KRaft**



- Apache Kafka Raft (KRaft) ist das Konsensprotokoll, das in KIP-500 eingeführt wurde, um die Abhängigkeit von Apache Kafka von ZooKeeper für das Metadatenmanagement zu entfernen.
- Dies vereinfacht die Architektur von Kafka erheblich, indem es die Verantwortung für Metadaten in Kafka selbst konsolidiert, anstatt sie zwischen zwei verschiedenen Systemen aufzuteilen: ZooKeeper und Kafka.
- Der KRaft-Modus nutzt einen neuen Quorum-Controller-Dienst in Kafka, der den früheren Controller ersetzt und eine ereignisbasierte Variante des Raft-Konsensprotokolls verwendet.
- Dieser Ansatz erleichtert die Verwaltung und Skalierung von Kafka-Clustern erheblich und erhöht die Robustheit des Systems.
- Besteht aus drei oder fünf Servern im Quorum
- Quorum:
 - Eine replizierte Gruppe von Servern in der gleichen Applikation nennt man Quorum
 - Im replicated mode haben alle Server im Quorum eine Kopie der gleichen Config Datei

Kafka Broker nutzen **KRaft** für:

- Cluster Management
- Fehlerfindung und Wiederherstellung
- Speicherung von Access Control Lists (ACL)



Aufgabenstellung:

- Erstellen Sie ein Topic mit 2 Partitionen auf dem Broker, welchen Sie in Aufgabe 1 eingerichtet haben
 - Alternativer Broker: `broker-1.k.anderscore.com`
- Welche Funktion und Auswirkung haben die Parameter:
 - `segment.ms` und `segment.bytes`
 - `cleanup.policy = delete` (oder `compact`)
 - `retention.ms` oder `retention.bytes`
 - `min.cleanable.dirty.ratio`
- Schreiben Sie die Zahlen 0...42 in das Topic und lesen Sie sie daraus. Wie sind die Zahlen geordnet?

Hinweise:

- Verwenden Sie die Kafka Command Line Tools um das Topic anzulegen
- Topic erzeugen:

```
bin/kafka-topics.sh --bootstrap-server localhost:9092 --create --topic myTopic --  
partitions 2 --replication-factor 1
```

Nachricht senden:

```
for zahl in `seq 0 42`; do echo $zahl | bin/kafka-console-producer.sh --broker-list  
localhost:9092 --topic myTopic; done.
```

Hinweis: Schneller geht's auch mit `kafkacat` statt `kafka-console-producer.sh`, da kein JVM-Process pro Iteration erzeugt wird – `kafka-console-producer.sh` bringt jedoch mehr Optionen

Nachricht Lesen:

```
bin/kafka-console-consumer.sh --bootstrap-server localhost:9092 --from-  
beginning --topic myTopic
```

Lektion 4 – Implementierung von Clients

Java Producer API

- Kafka Client, welcher Datensätze zum Kafka Cluster published
 - Thread Safe
 - Dependency Injection Scope: Singleton
 - Pufferung bei Verbindungsverlust

Java Consumer API

- Kafka Client, welcher Datensätze aus einem Kafka Cluster konsumiert
 - Transparenz bei Fehlern von Brokern
 - Passt sich an Migrationen von Partitionen im Cluster an
 - Interagiert mit Broker und erlaubt Zugriff auf dessen Consumer Groups

Name	Beschreibung
bootstrap.servers	Liste der Broker host/port Paare für initiale Verbindung zum Cluster
key.serializer/ value.serializer	Klasse zur Serialisierung von Keys/ Values. Muss das Serializer Interface implementieren
acks	Anzahl an Bestätigungen (Acknowledgements), die der Producer benötigt, bevor der Request fertig ist. acks=0 : Producer wartet nicht auf Bestätigungen vom Server acks=1 : Producer wartet, bis der Datensatz auf den Leader geschrieben wurde acks=all : Producer wartet, bis alle in-sync Replikate das Erhalten der Datensätze bestätigt haben

```
Properties props = new Properties();  
props.put(setting, value);
```


Erstellung eines Producers:

Klasse

```
public class KafkaProducer<K,V>
```

Wichtige Eigenschaften und Senden

```
Properties props = new Properties();  
props.put("bootstrap.servers", "localhost:9092");  
props.put("acks", "all");  
props.put("key.serializer",  
    "org.apache.kafka.common.serialization.StringSerializer");  
props.put("value.serializer",  
    "org.apache.kafka.common.serialization.StringSerializer");  
  
Producer<String, String> producer = new KafkaProducer<>(props);  
for (int i = 0; i < 100; i++)  
    producer.send(new ProducerRecord<String, String>("my-topic",  
        Integer.toString(i), Integer.toString(i)));  
producer.close();
```

- Die `send()` Methode ist non-blocking

- Gibt Datensatz in einen Buffer von wartenden Datensätzen über und gibt sofort ein Return zurück
- Effizienz: Batched einzelne Datensätze zusammen
- Falls nötig kann mit `.send(record).get()` ein block geforced werden

```
ProducerRecord<String, String> record = new ProducerRecord<String, String>("my-  
topic", "myKey", "myValue");
```

```
Future<RecordMetadata> metadata = producer.send(record);  
producer.close();
```

- **Retries:**

- Wie oft versucht der Producer bei einem Fehler Records erneut zu senden
- Kann zu **Änderung in der Reihenfolge** der Nachrichten führen!
- Anzahl der Connections kann angepasst werden

```
retry.backoff.ms=100 (Pause zwischen  
retries)  
retries=600 (Anzahl retries)
```

```
# default ist 5  
set max.in.flight.requests.per.connection=1
```

Default Linger:

- Buffer sendet sofort, auch bei ungenutztem Space
- Um die Anzahl an Requests zu verringern, kann Wartezeit konfiguriert werden
- Erhöht Effizienz bei minimaler Latenz

```
# größer als 0  
linger.ms = 1
```

Buffer Größe:

- Gesamtmenge an Speicher, welcher dem Producer für den Buffer zu Verfügung gestellt wird
- Wenn der Buffer voll ist, werden Send Requests geblockt (TimeoutException)

```
buffer.memory  
max.block.ms
```

- `send(record)` **äquivalent zu** `send(record, null)`

→ **Callback in zweitem Parameter überliefern**

```
ProducerRecord<byte[],byte[]> record = new ProducerRecord<String,String>("the-  
topic", key, value);  
producer.send(record,  
    new Callback() {  
        public void onCompletion(RecordMetadata metadata, Exception  
e) {  
            if(e != null) {  
                e.printStackTrace();  
            } else {  
                System.out.println("The offset of the record we  
just sent is: " + metadata.offset());  
            }  
        }  
    });
```

- **Reaktion auf Fehler:**

- Fehler: Metadata ist `null`
- Kein Fehler: Exception ist `null`

Name	Beschreibung
bootstrap.servers	Liste der Broker host/port Paare für initiale Verbindung zum Cluster
key.deserializer/ value.deserializer	Klasse zur Deserialisierung von Keys/ Values. Muss das Deserializer Interface implementieren
group.id	Zeigt an, zu welcher Consumer Group der Consumer gehört
enable.auto.commit	Bei true triggered der Consumer offset commits

```
Properties props = new Properties();  
props.setProperty(setting, value);
```

Erstellung eines Consumers:

Klasse

```
public class KafkaConsumer<K,V>
```

Wichtige Eigenschaften und Polling

```
Properties props = new Properties();
props.setProperty("bootstrap.servers", "localhost:9092");
props.setProperty("group.id", "test");
props.setProperty("enable.auto.commit", "true");
props.setProperty("auto.commit.interval.ms", "1000");
props.setProperty("key.deserializer", "org.apache.kafka.common.serialization.StringDeserializer");
props.setProperty("value.deserializer", "org.apache.kafka.common.serialization.StringDeserializer");

KafkaConsumer<String, String> consumer = new KafkaConsumer<>(props);
consumer.subscribe(Arrays.asList("foo", "bar"));
while (true) {
    ConsumerRecords<String, String> records = consumer.poll(Duration.ofMillis(100));
    for (ConsumerRecord<String, String> record : records)
        System.out.printf("offset = %d, key = %s, value = %s\n", record.offset(), record.key(),
record.value());
}
```

- **Die `poll()` Methode gibt alle verfügbaren Nachrichten zurück**

- Bis zu der maximalen Größe per Partition

```
# default 1048576 bytes  
max.partition.fetch.bytes
```

- Eine zu hohe Anzahl an Partitionen kann extreme Mengen an Daten zurückgeben

- Gesamtmenge von Datensätzen in einem einzelnen Poll kann reduziert werden (Chunking)

```
max.poll.records
```

Aufgabenstellung:

- Erzeugen Sie ein neues Java Projekt und binden Sie den Kafka Client ein
- Verbinden Sie sich mit Ihrem Kafka Broker
- Implementieren Sie einen Consumer: Lesen Sie alle Nachrichten aus dem Topic „HelloWorld“ aus
- Geben Sie die Nachrichten auf der Konsole aus
- Implementieren Sie einen Producer

- Im einfachsten Fall können Sie Kafka-Events ohne weitere Frameworks konsumieren.
- Hierzu müssen die entsprechenden Bibliotheken in das Projekt angebunden werden.

```
# Maven dependencies
<dependency>
  <groupId>org.apache.kafka</groupId>
  <artifactId>kafka-clients</artifactId>
  <version>3.7.0</version>
</dependency>
```

- Erstellen Sie ein neues Maven Projekt z.B. mit:

```
mvn archetype:generate -DgroupId=gs -DartifactId=kafka \
-DarchetypeArtifactId=maven-archetype-quickstart \
-DinteractiveMode=false
```

- Fügen Sie dann die Maven Dependency der Datei pom.xml hinzu
- Nutzen Sie die folgenden Klassen:

```
org.apache.kafka.clients.consumer.KafkaConsumer
org.apache.kafka.clients.producer.KafkaProducer
```

- Consumer property `auto.offset.reset` legt fest, was bei einem ungültigem Offset in Kafka für die Consumer Group des Consumers passiert
 - Wenn eine Consumer Group das erste mal startet
 - Wenn das Consumer Offset kleiner als das kleinste Offset ist
 - Wenn das Consumer Offset größer als das letzte Offset ist

Kann gesetzt werden auf:

- `earliest`: Automatischer Reset des Offsets zu kleinstem verfügbarem Wert
- `latest` (default): Automatischer Reset des Offsets zu letztem verfügbarem Wert
- `none`: Excepton, wenn kein früheres Offset für die Consumer Group gefunden werden kann

- KafkaConsumer API unterstützt Ansehen der Offsets und dynamisches Ändern des Nächsten zu Lesenden Offsets
- View Offsets:
 - `position(TopicPartition)`: Offset der nächsten Nachricht
 - `offsetsForTimes(Map<TopicPartition, Long> timestampsToSearch)`: sucht die Offsets für die angegebenen Partitionen nach Zeitstempel
- Change Offsets:
 - `seekToBeginning(Collection<TopicPartition>)`: Sucht erstes Offset von jeder der angegebenen Partitionen
 - `seekToEnd(Collection<TopicPartition>)`: Sucht letztes Offset von jeder der angegebenen Partitionen
 - `seek(TopicPartition, offset)`: Sucht angegebenes Offset in angegebener Partition

- **Beispiel:** Suchen bis zum Anfang aller Partitions, die von einem Consumer zu einer bestimmten Topic gelesen werden

```
consumer.subscribe(Arrays.asList("MyTopic"));  
consumer.poll(0);  
consumer.seekToBeginning(consumer.assignment());
```

- Default: `enable.auto.commit` ist auf `true`, alle 5 Sekunden, während des `poll()` Aufrufes
- **Problem:**
 - Szenario: Zwei Sekunden nach dem letzten Commit wird ein Rebalance ausgelöst, nach Rebalance starten Consumer bei der letzten Offset Position, die committed wurde
 - **In diesem Fall: Offset ist zwei Sekunden und alle Nachrichten aus diesen zwei Sekunden werden zweimal verarbeitet! (At least once)**

- `enable.auto.commit` auf `false` setzen
- `commitSync()`
 - Blockiert bis success, versucht so lange zu comitten, bis fataler Error auftritt
 - Für „at most once“: Aufruf von `commitSync()` direkt nach `poll()`, danach Nachrichten verarbeiten
 - Consumer sollte sicher gehen, dass alle Nachrichten die von `poll()` zurückgegeben wurden verarbeitet werden, sonst könnten Nachrichten verloren gehen
- `commitAsync()`
 - Sofortige Rückgabe
 - Nimmt optional einen Callback, der ausgelöst wird, wenn der Broker antwortet
 - Hat einen höheren Durchsatz, da der Consumer den nächsten Nachrichtenstapel verarbeiten kann, bevor der Commit zurückkehrt
 - **Nachteil:** Consumer kann später feststellen, dass die Übertragung fehlgeschlagen ist

- **Note:** Das Offset, was comitted wird (unabhängig ob manuell oder automatisch) ist das Offset der als nächstes zu lesenden Nachricht!
- **Default:** Kafka speichert Offsets in einer speziellen Topic: `__consumer_offsets`
- Ggf. möchte man Offsets außerhalb von Kafka speichern (z.B. in Datenbank-Tabelle)
 - Wert lesen, dann `seek()` verwenden, um beim Starten der Anwendung an die richtige Position zu gelangen

Default Partitioning Schema:

- Kafka hashed den Message Key und benutzt das Ergebnis, um die Nachricht einer Partition zuzuordnen
- Alle Messages mit gleichem Key gehen in die gleiche Partition
- Wenn der Key null ist, wird die Nachricht einer zufälligen Partition zugeordnet (round-robin Algorithmus)
- Dieses Verhalten kann überschrieben werden und ein eigenes Partitioning Schema eingeführt werden

Erstellen eines Custom Partitioners:

- Implementieren des `Partitioner` Interfaces
 - Enthält die `configure`, `close` und `partition` Methoden
 - `partition` enthält `topic`, `key`, `serialized key`, `value`, `serialized value` und `cluster metadata`
 - Gibt die Nummer der Partition zurück zu der die Nachricht gesendet wird

```
public class MyPartitioner implements Partitioner {  
  
    public void configure(Map<String, ?> configs) {}  
    public void close() {}  
  
    public int partition(String topic, Object key, byte[] keyBytes,  
                        Object value, byte[] valueBytes, Cluster cluster) {  
  
        //return desired partition  
  
    }  
}
```

Partitioner einbinden:

```
props.put(ProducerConfig.PARTITIONER_CLASS_CONFIG, MyPartitioner.class.getName());
```

- Implementieren Sie einen Custom Partitioner für den Producer aus Aufgabe 3, der Nachrichten sendet, die im Key die Zahlen von 1 bis 100 haben und alle gerade Zahlen zu Partition 0 zuordnet und alle ungeraden Zahlen zu Partition 1 zuordnet
- Implementieren Sie einen Custom Partitioner für den Producer aus Aufgabe 3, der alle Nachrichten mit einem bestimmten Key in eine bestimmte Partition ordnet und alle anderen Nachrichten auf die restlichen Partitionen verteilt

Alternative zu einem Custom Partitioner

- Es ist möglich die Partition, in die eine Nachricht gehen soll, zu bestimmen, wenn der `ProducerRecord` erstellt wird:

```
ProducerRecord<String, String> record = new ProducerRecord<String,  
String>("my_topic", 0, key, value);
```

→ Ordnet die Nachricht der Partition 0 zu

Diskussion: Welche Methode ist bevorzugt?

- Implementieren Sie error handling für den Consumer in Aufgabe 3
 - Wenn eine Nachricht nicht verarbeitet werden kann, dann wird sie in die dead letter queue geschrieben
 - Der Consumer loggt jeden erfolgreich manuell comitteten offset
 - Der Consumer erhält über einen Kommandozeilenparameter den letzten erfolgreich bearbeiteten Offset und beginnt mit der nächsten Nachricht – verwalten Sie nur eine partition.

- Implementieren sie error handling für den Producer in Aufgabe 3
 - Der Producer loggt den offset einer erfolgreich übermittelten Nachricht. Synchronisieren Sie den commit

Spring for Kafka

- Version 3.1.2
- Basiert auf Kernkonzepten von Spring (z.B. DI, Annotationen, Templates)
- Wird verwendet, um Kafka basierte Messaging Lösungen zu entwickeln
- Bietet Template für High-Level Abstraktion für das Senden von Messages
- Bietet Support für Message-driven POJOs
- Es kann plain Java zum Versenden und Empfangen von Messages genutzt werden
- Java mit Konfiguration
- Oder am simpelsten mit **Spring Boot**

Dependencies

- spring-kafka JAR und alle seine Dependencies
- Am einfachsten mit Maven

```
<dependency>  
  <groupId>org.springframework.kafka</groupId>  
  <artifactId>spring-kafka</artifactId>  
  <version>3.1.2</version>  
</dependency>
```

Spring Boot Beispiel:

- Anwendung sendet 3 Nachrichten an ein Topic
- Nachrichten werden empfangen
- Anwendung wird beendet

Voreinstellungen

- Es wird Group Management benutzt, um Topics und Partitions Consumern zuzuordnen
- Hierfür muss eine Gruppe erstellt werden:

```
spring.kafka.consumer.group-id=foo
```

- Der Container könnte nach dem Verstand der Nachrichten starten
- Es muss ein Offset eingestellt werden, um sicher zu gehen, dass die neue Consumer Group die Nachrichten auch bekommt:

```
spring.kafka.consumer.auto-offset-reset=earliest
```



```
@SpringBootApplication
public class Application implements CommandLineRunner {

    public static Logger logger = LoggerFactory.getLogger(Application.class);

    public static void main(String[] args) {
        SpringApplication.run(Application.class, args).close();
    }

    @Autowired private KafkaTemplate<String, String> template;
    private final CountDownLatch latch = new CountDownLatch(3);

    @Override
    public void run(String... args) throws Exception {
        this.template.send("myTopic", "foo1");
        this.template.send("myTopic", "foo2");
        this.template.send("myTopic", "foo3");
        latch.await(60, TimeUnit.SECONDS);
        logger.info("All received");
    }

    @KafkaListener(topics = "myTopic")
    public void listen(ConsumerRecord<?, ?> cr) throws Exception {
        logger.info(cr.toString());
        latch.countDown();
    }
}
```


Aufgabenstellung:

- Erstellen Sie ein Spring Boot Projekt
- Binden Sie die Kafka Bibliotheken ein und konfigurieren Ihren Broker auf Port 9092
- Konsumieren Sie das Topic „Hallo Welt“ und geben Sie es auf der Konsole aus
- Senden Sie eine Nachricht an das Topic
- Optional: Führen sie synchrone Requests aus

- **Properties:** `group-id` und `auto-offset-reset` anpassen
- Wie ein **neues Spring-Boot-Projekt** anzulegen ist, wird hier beschrieben:
 - <https://spring.io/guides/gs/spring-boot/>
 - <https://start.spring.io>
 - <https://www.baeldung.com/spring-kafka>


Lektion 5 – Analyse und Transformation

- Framework zum Streaming von Daten zwischen Kafka und externen Datensystemen
- Herausgeber: confluent
- Skalierbar, einfach und zuverlässig
- **Use cases:** Komplette SQL Datenbank zu Kafka streamen, Streamen von Kafka Topics zu Elasticsearch für Indexierung, ...




- Im Kern ist Kafka Connect ein Kafka Client der die standard Producer und Consumer APIs benutzt
- Vorteile gegenüber „DIY“ Producer und Consumer:
 - Getestete Connectors für gebräuchliche Datenquellen
 - Unterstützt fault tolerance und automatisches load balancing
 - Keine komplizierte Implementierung, nur configuration files für Kafka Connect nötig
 - Einfach erweiterbar und anpassbar durch Entwickler

- **Connector:** Logical Job bzw. Plugin zum Managen vom Datenaustausch zwischen Kafka und anderem System
 - *Connector Sources:* Datenübertragung vom externen System zu Kafka (Producer Client)
 - *Connector Sinks:* Übertragung von Kafka Daten in ein externes System (Consumer Client)
- **Task:** Connector Jobs werden in Tasks zerlegt, die den Datenaustausch durchführen (stateless)
- **Workers:** Laufende Prozesse für Connectors und Tasks (standalone vs. distributed)



Quelle: <https://docs.confluent.io/platform/current/connect/concepts.html#:~:text=handles%20connector%20errors-,Connectors,defined%20in%20a%20connector%20plugin.>

- **Converter:** Stellt das Datenformat bereit, das von Kafka gelesen bzw. in Kafka geschrieben wird
 - Konverter zwischen Kafka und Data Source bzw. Data Sink (z.B JSON Converter)
 - Entkoppelt von Connectors: Beliebiger Connector kann für beliebiges Serialisationsformat verwendet werden
- **Transforms:** Anpassung von Nachrichten von oder zu einem Connector (z.B. Filter)
- **Dead Letter Queue:** Behandlung von Connector Fehlern (*auch für Consumer relevant!*)



Kafka ist eine Streaming Plattform

- **Stream** = unbeschränkte, kontinuierlich updatende Datenmenge
- Streams von Datensätzen publishen und abonnieren
 - ähnelt einer Message Queue oder einem Enterprise Messaging System
- **Kafka Streams API:** Java Bibliothek zum Aufbau verteilter Stream processing applications in Kafka-Clustern

→ Einfache Anwendung


- Speichern von Datensatz-Streams (fault tolerance)
- Verarbeiten von Datensätzen sobald diese auftreten

Anwendung von Streams

- Real Time Streaming Datapipelines
 - Zuverlässiger Austausch von Daten zwischen Systemen oder Anwendungen
- Real Time Streaming Anwendungen
 - Auf Daten Streams reagieren oder diese transformieren

- Ähnlich zu Spark Streaming, Apache Storm und Co.
- KafkaStreams DSL (map, flatMap, count, ...) vs. low-level Processor API
- Abstraktion: KStream, KTable, ksqlDB

```
public class WordCountApplication {  
  
    public static void main(final String[] args) throws Exception {  
        Properties props = new Properties();  
        props.put(StreamsConfig.APPLICATION_ID_CONFIG, "wordcount-application");  
        props.put(StreamsConfig.BOOTSTRAP_SERVERS_CONFIG, "kafka-broker1:9092");  
        props.put(StreamsConfig.DEFAULT_KEY_SERDE_CLASS_CONFIG, Serdes.String().getClass());  
        props.put(StreamsConfig.DEFAULT_VALUE_SERDE_CLASS_CONFIG, Serdes.String().getClass());  
  
        StreamsBuilder builder = new StreamsBuilder();  
        KStream<String, String> textLines = builder.stream("TextLinesTopic");  
        KTable<String, Long> wordCounts = textLines  
            .flatMapValues(textLine -> Arrays.asList(textLine.toLowerCase().split("\\W+")))  
            .groupBy((key, word) -> word)  
            .count(Materialized.<String, Long, KeyValueStore<Bytes, byte[]>>as("counts-store"));  
        wordCounts.toStream().to("WordsWithCountsTopic", Produced.with(Serdes.String(), Serdes.Long()));  
  
        KafkaStreams streams = new KafkaStreams(builder.build(), props);  
        streams.start();  
    }  
}
```



Quelle: <https://kafka.apache.org/documentation/streams/>

Quelle: <https://kafka.apache.org/20/documentation/streams/core-concepts>

- **KStream**

- Abstraktion des Record Streams
- Alle Messages werden als Insert betrachtet

- **KTable**

- Abstraktion des Changelog Streams
- Messages werden als Insert bzw. Update (sog. „Upsert“) betrachtet

- **Beispiel:** Summation

- Nachricht 1: {id: 'apple', value: 1}
- Nachricht 2: {id: 'apple', value: 2}
- Ergebnis:
 - KStream: 3 (Summe der Records)
 - KTable: 2 (Update für Nachricht mit ID 'apple')

Beschreibung

- Kafka-Streams erlauben die „Echtzeit“-Auswertung und Transformation von Daten, die auf Kafka-Topics veröffentlicht werden
- In der Dokumentation wird die Verwendung zur Zählung der Worte im Stream verwendet:
<https://kafka.apache.org/documentation/streams/>

Aufgabenstellung:

- Starten Sie das Beispiel aus der Dokumentation
- Zählen Sie die Wörter im Topic „Hello World“ auf dem Broker broker-1.k.anderscore.com (Port 9092)

Hinweise:

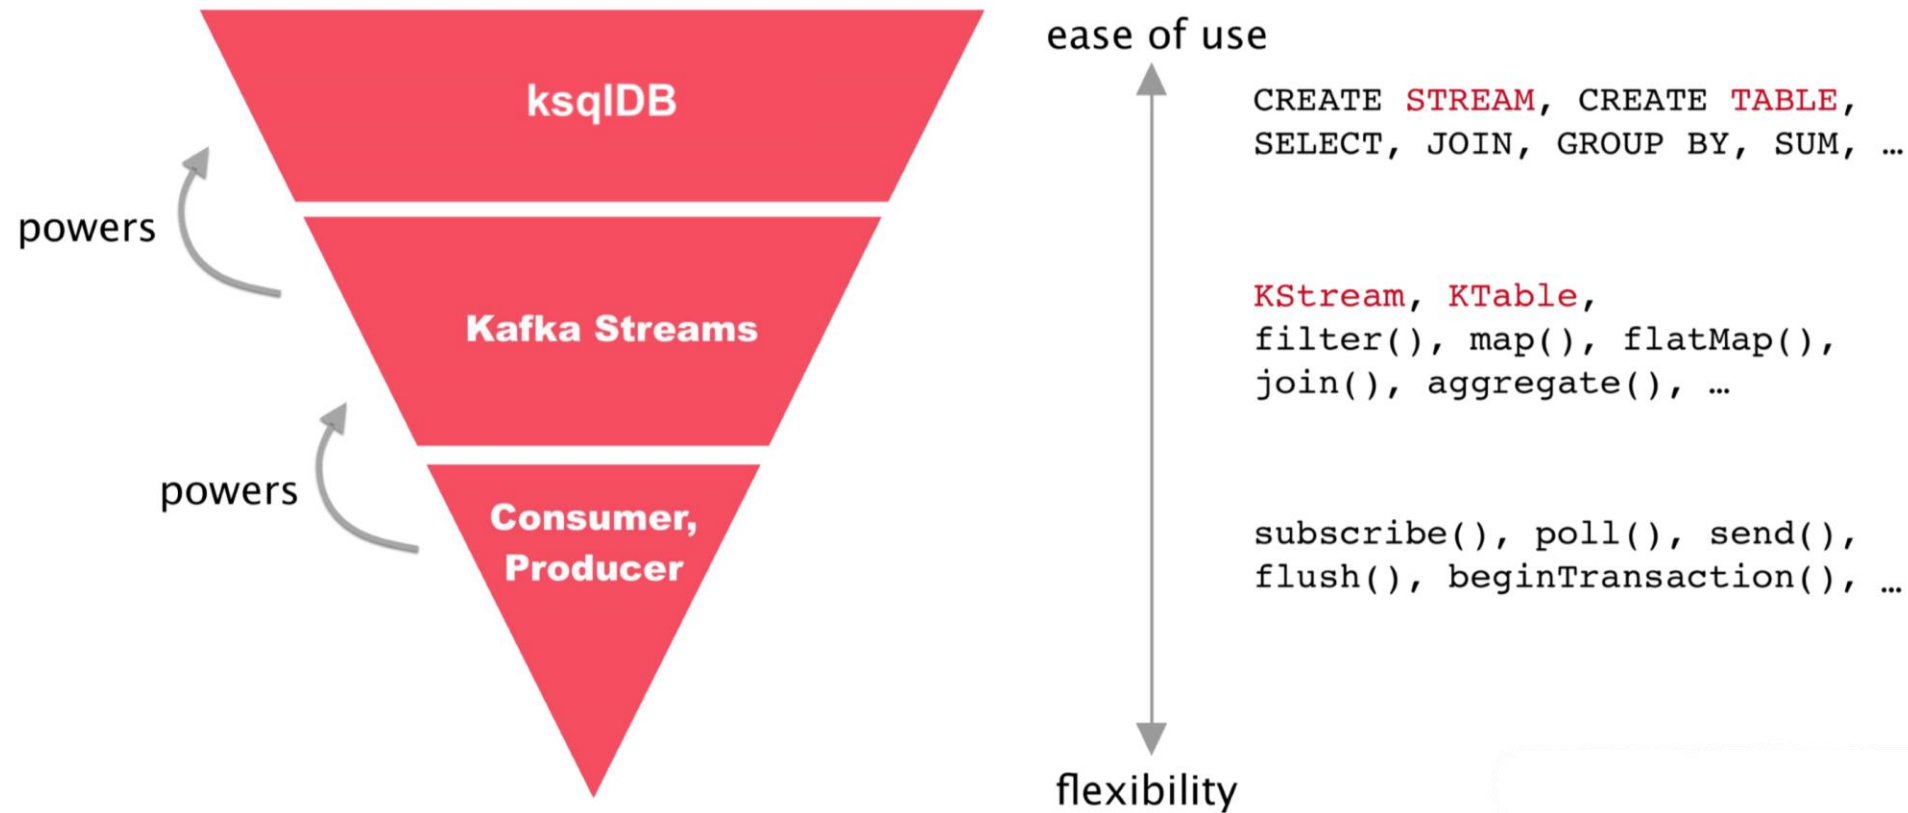
- Erzeugen Sie die Projektstruktur wie in Aufgabe 4
- Für Kafka-Streams wird eine weitere Maven Dependency benötigt:

```
<dependency>  
<groupId>org.apache.kafka</groupId>  
<artifactId>kafka-streams</artifactId>  
<version>3.7.0</version>  
</dependency>
```

- Die Streams aktualisieren sich, wenn Sie Nachrichten senden.
- Das Codebeispiel schreibt das Ergebnis in den Stream `WordsWithCountsTopic`, den Sie konsumieren müssen.
- Die Ergebnisse erscheinen innerhalb des eingestellten Intervalls – per default müssen Sie ein paar Sekunden warten.

Event Streaming Database

- Hilft beim Erstellen komplexer Stream Processing Anwendungen mit Kafka
- Abfragen, Lesen, Schreiben und Verarbeiten von Daten
- Deklarative Definition von Tabellen, Streams und Konnektoren
- Dynamische Joins
- Lightweight SQL Syntax
- SQL-like Interface
- Runtime: ksqlDB Engine
- Community Component von Confluent
- Alternative / Aufbau zu Kafkas Stream API
- Besser für:
 - Streaming ETL Pipelines
 - Reaktion auf kontinuierliche Real-Time Business Requests
 - Anomalien erkennen



Quelle: <https://docs.ksqldb.io/en/latest/concepts/ksqldb-and-kafka-streams>

ksqlDB:

```
CREATE STREAM fraudulent_payments AS
SELECT fraudProbability(data) FROM payments WHERE fraudProbability(data) > 0.8
EMIT CHANGES;
```

Kafka Streams:

```
public class FraudFilteringApplication {
    StreamsBuilder builder = new StreamsBuilder();
    KStream<String, Payment> fraudulentPayments = builder
        .stream("payments-topic")
        .filter((customer, payment) -> payment.getFraudProbability() > 0.8);
    .to("fraudulent-payments-topic");

    Properties config = new Properties();
    config.put(StreamsConfig.APPLICATION_ID_CONFIG, "fraud-filtering-app");
    config.put(StreamsConfig.BOOTSTRAP_SERVERS_CONFIG, "kafka-broker1:9092");

    new KafkaStreams(builder.build(), config).start();
}
```

Nach: <https://docs.ksqldb.io/en/latest/concepts/ksqldb-and-kafka-streams>

Lektion 6 – Broker Operations

- **Config Files**
 - Liegen im Ordner kafka/config/kraft/
- **Broker config**
 - Beispiel-File unter kafka/config/kraft/broker.properties
- **Basic Keys**
 - process.roles=broker
 - Server nimmt an, ausschließlich als Broker zu fungieren
- **node.id**
 - Eindeutige identifizierung des Servers
 - Beispiel: node.id=2
- **controller.quorum.voters**
 - Eine durch Komma getrennte Liste der quorum voters
 - Beispiel:
 - controller.quorum.voters=1@localhost:9093
- <https://docs.confluent.io/platform/current/kafka-metadata/config-kraft.html#server-basics>
- <https://docs.confluent.io/platform/current/installation/configuration/broker-configs.html>

Live Update

Einige Configs können ohne Broker Restart geändert werden

- ready-only: Nur mit Neustart
- per-broker: Dynamisch für jeden Broker einzeln
- cluster-wide: Dynamisch gesamtes Cluster oder einzelne Broker

Beispiel Live Update:

- Broker id 0
- Anzahl der Log Cleaner Threads

```
> bin/kafka-configs.sh --bootstrap-server localhost:9092 --entity-type brokers --entity-name 1 --  
alter --add-config log.cleaner.threads=2
```

<https://docs.confluent.io/platform/current/kafka/dynamic-config.html>

- **Default:** Topics werden automatisch erstellt, wenn sie das erste mal von einem Client benutzt werden
 - Replication factor ist 1, eine einzelene Partition
 - In production environments: Ggf. `auto.create.topics.enable` deaktivieren
- **Topic manuell erstellen** (vgl. Aufgabe 2):

```
bin/kafka-topics.sh --bootstrap-server localhost:9092 --create --topic myTopic --  
partitions 2 --replication-factor 1
```

- **Topic ändern:**

```
bin/kafka-topics.sh --bootstrap-server localhost:9092 --alter --topic myTopic --  
partitions 3
```

Achtung: Ändern der Anzahl an Partitionen kann zu Problemen in der Anwendungslogik führen!

- **Topic löschen:**

```
bin/kafka-topics.sh --bootstrap-server localhost:9092 --  
delete --topic myTopic
```

- Alle Broker müssen `delete.topic.enable` auf `true` gesetzt haben
 - Default ist `false`, falls es nicht gesetzt ist, wird Löschkommando ignoriert
- Alle Broker müssen laufen, damit der Löschvorgang erfolgreich ist

Topic Level Einstellungen: Beispiele

- cleanup.policy
 - compression.type
 - delete.retention.ms
 - file.delete.delay.ms
 - flush.messages
 - flush.ms
 - follower.replication.throttled.replicas
 - index.interval.bytes
 - leader.replication.throttled.replicas
 - min./max.compaction.lag.ms
 - max.message.bytes
 - message.format.version
 - message.timestamp.difference.max.ms
 - message.timestamp.type
 - min.cleanable.dirty.ratio
 - min.insync.replicas
 - preallocate
 - retention.bytes
 - retention.ms
 - segmentet.bytes
 - segment.index.bytes
 - segment.jitter.ms
 - segment.ms
 - unclean.leader.election.enable
 - message.downconversion.enable
-
- **Gesamte Liste:** <https://kafka.apache.org/documentation/#topicconfigs>

Topic Konfiguration

- Relevante Konfiguration
 - Server Default
 - Per-Topic Override

Override kann beim Erstellen eines Topics in der Kafka Shell eingestellt werden

- `--config`
- Eine oder mehrere Einstellungen

```
> bin/kafka-topics.sh --bootstrap-server localhost:9092 --create --topic my-topic --partitions 1 \  
    --replication-factor 1 --config max.message.bytes=64000 --config flush.messages=1
```


Overrides können auch später mit `add-config` konfiguriert werden

- Im folgenden Beispiel wird die `max.message.bytes` upgedated:

```
> bin/kafka-configs.sh --bootstrap-server localhost:9092 --entity-type topics --entity-name my-topic  
--alter --add-config max.message.bytes=128000
```

- Overrides überprüfen mit `--describe`:

```
> bin/kafka-configs.sh --bootstrap-server localhost:9092 --entity-type topics --entity-name my-topic  
--describe
```

- Override entfernen mit `--alter --delete-config`:

```
> bin/kafka-configs.sh --bootstrap-server localhost:9092 --entity-type topics --entity-name my-topic  
--alter --delete-config max.message.bytes
```

Lektion 7 – Best Practices

Producer

- Automatische Retries möglichst abschalten (Reordering)
- acks = all für “Konsistenz über Verfügbarkeit” (vgl. CAP Theorem)
- Mehrere Bootstrap Server angeben (Fehlertoleranz)

Consumer

- Nicht zu viele Daten auf einmal pollen (Netzwerklast, OutOfMemoryError)
- Auto-Commit beachten und möglichst abschalten
- Topics mit Consumer Offsets richtig konfigurieren (Compaction und Deletion!)
- At-least-once-Semantik meist beste Wahl
- Mehrere Bootstrap Server angeben (Fehlertoleranz)

Nach: https://media.ccc.de/v/froscon2018-2213-apache_kafka_lessons_learned

Broker

- Defaults setzen und bei Bedarf überschreiben (Fehlervermeidung)

Topics

- Deletion vs. Compaction **fachlich** entscheiden
- retention.ms wirkt nur bei Deletion, max.cleanable.dirty.ratio nur bei Compaction
- Automatisiert anlegen (z.B. Skript)
- Richtwert: ~ 10 bis 30 Partitionen pro Topic

Streams

- Dead Letter Queue vorsehen (z.B. Topic)

Nach: https://media.ccc.de/v/froscon2018-2213-apache_kafka_lessons_learned


Lektion 8 – Ausblick

Microservices:

- Fachlicher Schnitt (Bounded Contexts)
- Weniger Verantwortlichkeiten → leichter austauschbar
- Potential für bessere Skalierbarkeit und Fehlertoleranz
- Lose Kopplung zwischen Services

Beispiel:

- Simple Business System in Microservice Architektur
- Asynchrone Kommunikation über Messages
- Eventbasiert




Quelle: WP Microservices in the Apache Kafka Ecosystem Confluent 2017

Microservice Environment

- Event-basiert
- Request / Response basiert
- **Hybrider Ansatz:**
 - Service Discovery
 - Synchrone Vorgänge
 - Asynchrone, Event-basierte Flows
 - Anpassbarkeit
 - Skalierbarkeit

Praxisbeispiel:

- Asynchroner eMail Service mit Kafka Streams
- Order und Payment Stream joinen
- Ergebnis zu einem Lookup Table von Kunden joinen
- E-Mail zu jedem resultierenden Tuple versenden



Quelle: WP Microservices in the Apache Kafka Ecosystem Confluent 2017

Apache Avro

- Data Serialization System (& RPC, Container)
- Vergleichbar mit: Thrift, Protocol Buffers
- Aktuell: 1.11.1
- Bindings: Java, Python, C, C++, C#, JavaScript, ... (3rd party)
- Teil des Hadoop Projekts
- Serialization Format für persistente Daten
- Wire Format für Nodes und Clients



Schema für Daten in JSON

- Getrennt von den Nutzdaten
- Code-Generatoren (code-first, contract-first)
- Gemeinsames Schema für verschiedene μ Services


```
{  
  "namespace": "example.avro",  
  "type": "record",  
  "name": "User",  
  "fields": [  
    {"name": "name", "type": "string"},  
    {"name": "favorite_number", "type": ["int", "null"]},  
    {"name": "favorite_color", "type": ["string", "null"]}  
  ]  
}
```

Quelle: https://en.wikipedia.org/wiki/Apache_Avro

Confluent Schema Registry (OpenSource)



- Historisierung, Java & RESTful API, Migration
- Kein Transport mit den Daten (Performance)
- Persistenz: Kafka-Topic
- Command Line Client

Avro als wire-format?

- Einheitliches Schema für Daten zwischen Systemen
- **Pro:**
 - Integration (confluent platform)
- **Contra:**
 - XML & JSON deutlich weiter verbreitet

Beschreibung:

- Austausch von Nachrichten zwischen zwei Services über Kafka
- Serialisierung und Deserialisierung über Avro mit JSON-Schemata
- Generierung von Java Klassen aus Metadaten
- Die Confluent Platform enthält eine Avro Schema Registry, mit der Schemas unternehmensweit verwaltet werden können.
- Die OpenSource-Ausgabe der Confluent-Platform ist auf `broker-2.k.anderscore.com` installiert.
- Confluent bietet ein Maven Plug-In zum Schema-Download an:
<https://docs.confluent.io/platform/current/schema-registry/develop/maven-plugin.html>
- Weitere Infos: <https://docs.confluent.io/current/schema-registry/docs>

Aufgabenstellung:

- Unter folgendem Link liegt ein Producer, welcher Personendaten (SteuerID, Name, Vorname) sendet:
<https://github.com/anderscore-gmbh/kafka-24.03.1/tree/main/Aufgabe6-Producer>
- Implementieren Sie einen Consumer, welcher die Daten deserialisiert und auf der Konsole ausgibt.

Schemata:

<http://broker-2.k.anderscore.com:8081/subjects>

<http://broker-2.k.anderscore.com:8081/schemas/ids/1>

<http://broker-2.k.anderscore.com:8081/schemas/ids/2>

Hinweise:

- Verwenden Sie den Consumer aus Aufgabe 4 als Vorlage
- Die Schemata können Sie aus dem Producer übernehmen oder aus der Registry laden.
- Beachten Sie die pom.xml des Producers zu Abhängigkeit und Generator-Konfiguration
- Simulieren Sie einen Tippfehler: Benennen Sie das Feld firstName in fristName um und generieren Sie den Avro-Code für den Consumer erneut. Was passiert beim Start?
- Tipp: Ändern Sie die Consumer Group bei Bedarf
- Ein Beispiel für den Consumer finden Sie unter:

<https://github.com/anderscore-gmbh/kafka-24.03.1/tree/master/Aufgabe6-Consumer>

Topics und Partitions

- Senden von Messages an einen Topic, Auswerten der recordMetadata
- Konsumieren eines Topics, Validieren der Messages
- Command Line, Kafka Client API (low-level)

Producer und Consumer

- Klassische Unit Tests mit Mocks
- Programmatische Integration Tests mit *EmbeddedKafkaCluster*
- Programmatische Integration Tests mit *Spring Boot*
- Deklarative Integration Tests mit *Zerocode*

Microservices

- End-to-end Tests mit *Testcontainers*

Beispiel: Spring Boot

```
@SpringBootTest
@DirtiesContext
@EmbeddedKafka(partitions = 1, brokerProperties = { "listeners=PLAINTEXT://localhost:9092", "port=9092" })
class EmbeddedKafkaIntegrationTest {

    @Autowired
    private KafkaConsumer consumer;

    @Autowired
    private KafkaProducer producer;

    @Value("${test.topic}")
    private String topic;

    @Test
    public void givenEmbeddedKafkaBroker_whenSendingtoSimpleProducer_thenMessageReceived()
        throws Exception {
        producer.send(topic, "Sending with own simple KafkaProducer");
        consumer.getLatch().await(10000, TimeUnit.MILLISECONDS);

        assertThat(consumer.getLatch().getCount(), equalTo(0L));
        assertThat(consumer.getPayload(), containsString("embedded-test-topic"));
    }
}
```

Quelle: <https://www.baeldung.com/spring-boot-kafka-testing>

Weiterführende Literatur zum Thema

- <https://dzone.com/articles/a-quick-and-practical-example-of-kafka-testing>
- <https://github.com/authorjapps/zerocode/wiki/Kafka-Testing-Introduction>
- <https://medium.com/test-kafka-based-applications/https-medium-com-testing-kafka-based-applications-85d8951cec43>
- <https://github.com/apache/kafka/tree/trunk/streams/src/test/java/org/apache/kafka/streams/integration/utils>
- <https://www.baeldung.com/spring-boot-kafka-testing>
- <https://www.testcontainers.org/modules/kafka>